

ĐẠI HỌC TRÀ VINH
TRƯỜNG KỸ THUẬT VÀ CÔNG NGHỆ



KHÓA LUẬN TỐT NGHIỆP

**MÔ HÌNH DỰ ĐOÁN TỐC ĐỘ TẠO HYDRO
TRONG HỆ THỐNG KÝ KHÍ DỰA TRÊN DỮ LIỆU**

Giảng viên hướng dẫn: **TS. NGUYỄN BẢO ÂN**

Sinh viên thực hiện: **TRẦN MINH ĐIỀN**

Mã số sinh viên: **110122050**

Lớp: **DA22TTA**

Khóa: **2022**

Vĩnh Long, tháng 6 năm 2026

ĐẠI HỌC TRÀ VINH
TRƯỜNG KỸ THUẬT VÀ CÔNG NGHỆ



KHÓA LUẬN TỐT NGHIỆP

**MÔ HÌNH DỰ ĐOÁN TỐC ĐỘ TẠO HYDRO
TRONG HỆ THỐNG KÝ KHÍ DỰA TRÊN DỮ LIỆU**

Giảng viên hướng dẫn: **TS. NGUYỄN BẢO ÂN**

Sinh viên thực hiện: **TRẦN MINH ĐIỀN**

Mã số sinh viên: **110122050**

Lớp: **DA22TTA**

Khóa: **2022**

Vĩnh Long, tháng 6 năm 2026

LỜI MỞ ĐẦU

Nhu cầu năng lượng toàn cầu đang gia tăng nhanh chóng trong bối cảnh biến đổi khí hậu và cạn kiệt nhiên liệu hóa thạch. Trong số các nguồn năng lượng tái tạo, hydrogen sinh học sản xuất bằng quá trình lên men tối nổi lên như một giải pháp tiềm năng nhờ đặc tính không phát thải carbon khi đốt cháy và khả năng tận dụng cơ chất hữu cơ phong phú. Tuy nhiên, tốc độ tạo hydro chịu ảnh hưởng đồng thời của nhiều yếu tố sinh hóa phức tạp, khiến việc tối ưu vận hành bể phản ứng sinh học bằng phương pháp thí nghiệm truyền thống trở nên tốn kém và khó khăn.

Xuất phát từ thực tiễn đó, khóa luận “Mô hình dự đoán tốc độ tạo hydro trong hệ thống kỵ khí dựa trên dữ liệu” đề xuất một quy trình kết hợp Grey Relational Analysis để xếp hạng mức độ ảnh hưởng của 11 đặc trưng sinh hóa, huấn luyện và so sánh 5 mô hình học máy gồm KNN, RF, XGBoost, SVR, DT để dự đoán HPR, xác định tổ hợp đặc trưng tối ưu bằng phương pháp thêm đặc trưng tuần tự, và giải thích mô hình bằng SHAP. Dữ liệu nghiên cứu gồm 197 mẫu thu thập từ hệ thống reactor quy mô thử nghiệm sử dụng sucrose.

Kết quả cho thấy VFA, Butyrate và Acetate là ba yếu tố ảnh hưởng lớn nhất đến HPR; mô hình KNN đạt hiệu suất tốt nhất ($R^2 = 0.817$). Nghiên cứu cung cấp mô hình dự đoán HPR hiệu quả cùng quy trình phân tích đặc trưng toàn diện, góp phần giảm chi phí thí nghiệm và hỗ trợ vận hành bể phản ứng sinh học kỵ khí.

Khóa luận là kết quả của quá trình nghiên cứu quốc tế trong khuôn khổ chương trình thực tập tài năng TEEP do Bộ Giáo dục Đài Loan tài trợ, thực hiện tại Đại học Phùng Giáp, Đài Loan. Đề tài được đặt dưới sự đồng hướng dẫn của Giáo sư Hsi-Min Chen (Khoa Kỹ thuật Thông tin và Khoa học Máy tính) và Giáo sư Chih-Hsin Shih (Khoa Kỹ thuật Hóa học), kết tinh sự giao thoa liên ngành giữa trí tuệ nhân tạo và công nghệ sinh hóa môi trường.

Từ khóa: Biohydrogen, Dark fermentation, Grey Relational Analysis, Machine Learning, SHAP.

LỜI CẢM ƠN

Tôi xin gửi lời cảm ơn chân thành và sâu sắc nhất đến **TS. Nguyễn Bảo Ân** – giảng viên hướng dẫn khóa luận. Thầy đã tận tình hướng dẫn, định hướng nghiên cứu và truyền đạt cho tôi những kiến thức quý báu trong suốt quá trình thực hiện đề tài.

Tôi xin trân trọng cảm ơn Đại học Trà Vinh, đặc biệt là quý thầy cô Trường Kỹ thuật và Công nghệ, đã tạo nền tảng kiến thức và điều kiện để tôi hoàn thành chương trình học. Tôi xin gửi lời tri ân sâu sắc đến chương trình thực tập tài năng TEEP của Bộ Giáo dục Đài Loan – chương trình đã mở ra cho tôi cơ hội quý giá được học tập và nghiên cứu trong môi trường học thuật quốc tế tại Đại học Phùng Giáp, Đài Loan. Tôi đặc biệt biết ơn hai người thầy đã trực tiếp dìu dắt tôi trên hành trình này: Giáo sư Hsi-Min Chen (Khoa Kỹ thuật Thông tin và Khoa học Máy tính) và Giáo sư Chih-Hsin Shih (Khoa Kỹ thuật Hóa học). Sự đồng hành liên ngành giữa hai thầy – một bên là chiều sâu về trí tuệ nhân tạo, một bên là nền tảng vững chắc về kỹ thuật hóa học – đã định hình tư duy nghiên cứu và giúp tôi hoàn thiện đề tài. Tôi cũng chân thành cảm ơn các thầy cô, anh chị tại phòng thí nghiệm đã tiếp nhận, hỗ trợ thiết bị, dữ liệu thực nghiệm và tạo môi trường nghiên cứu thuận lợi trong suốt thời gian tôi thực hiện khóa luận.

Cuối cùng, tôi xin bày tỏ lòng biết ơn sâu sắc đến gia đình, người thân và bạn bè đã luôn động viên, khích lệ và đồng hành cùng tôi trong suốt quá trình học tập và hoàn thành khóa luận này.

[illegible]

NHẬN XÉT
(Của giảng viên hướng dẫn trong đề án, khoá luận của sinh viên)

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Giảng viên hướng dẫn
(ký và ghi rõ họ tên)

BẢN NHẬN XÉT ĐỒ ÁN, KHÓA LUẬN TỐT NGHIỆP
(Của giảng viên hướng dẫn)

Họ và tên sinh viên: MSSV:

Ngành: Khóa:

Tên đề tài:

Họ và tên Giáo viên hướng dẫn:

Chức danh: Học vị:

NHẬN XÉT

1. Nội dung đề tài:

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

2. Ưu điểm:

.....

.....

.....

.....

3. Khuyết điểm:

.....

.....

.....

.....

4. Điểm mới của đề tài:

.....

.....

.....

.....

5. Giá trị thực tiễn của đề tài:

.....

.....

.....

.....

6. Đề nghị sửa chữa, bổ sung:

.....

.....

.....

.....

7. Đánh giá:

.....
.....
.....

Vĩnh Long, ngày tháng năm 20...

Giảng viên hướng dẫn
(Ký & ghi rõ họ tên)

NHẬN XÉT

(Của giảng viên chấm trong đề án, khoá luận của sinh viên)

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Giảng viên chấm

(ký và ghi rõ họ tên)

BẢN NHẬN XÉT ĐỒ ÁN, KHÓA LUẬN TỐT NGHIỆP

(Của cán bộ chấm đồ án, khóa luận)

Họ và tên người nhận xét:

Chức danh: Học vị:

Chuyên ngành:

Cơ quan công tác:

Tên sinh viên:

Tên đề tài đồ án, khóa luận tốt nghiệp:

I. Ý KIẾN NHẬN XÉT

1. Nội dung:

.....

.....

.....

.....

.....

.....

.....

.....

.....

2. Điểm mới các kết quả của đồ án, khóa luận:

.....

.....

.....

3. Ứng dụng thực tế:

.....

.....

.....

.....

.....

II. CÁC VẤN ĐỀ CẦN LÀM RÕ

(Các câu hỏi của giáo viên phản biện)

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

III. KẾT LUẬN

(Ghi rõ đồng ý hay không đồng ý cho bảo vệ đồ án, khóa luận tốt nghiệp)

.....

.....

.....
.....

....., ngày tháng năm 20...

Người nhận xét
(Ký & ghi rõ họ tên)

MỤC LỤC

Danh mục các bảng, sơ đồ, hình	14
Kí hiệu các cụm từ viết tắt	15
Chương 1. Giới thiệu	1
1.1 Bối cảnh nghiên cứu	1
1.2 Lý do chọn đề tài	4
1.3 Đối tượng và phạm vi nghiên cứu	5
1.3.1 Đối tượng nghiên cứu	5
1.3.2 Phạm vi nghiên cứu	5
1.4 Mục tiêu nghiên cứu	5
1.4.1 Mục tiêu tổng quát	5
1.4.2 Mục tiêu cụ thể	6
1.5 Câu hỏi nghiên cứu	6
1.6 Ý nghĩa khoa học và thực tiễn	6
1.6.1 Ý nghĩa khoa học	6
1.6.2 Ý nghĩa thực tiễn	7
1.7 Cấu trúc báo cáo	7
Chương 2. Cơ sở lý thuyết	8
2.1 Tổng quan các nghiên cứu liên quan	8
2.1.1 Học máy trong dự đoán hiệu suất lên men kỵ khí	8
2.1.2 Khoảng trống nghiên cứu	9
2.2 Cơ sở lý thuyết	9
2.2.1 Sản xuất hydrogen sinh học bằng lên men tối	9
2.2.2 Các yếu tố ảnh hưởng đến HPR	10
2.2.3 GRA	11
2.2.4 SVR	12
2.2.5 DT	12
2.2.6 RF	13
2.2.7 XGBoost	13
2.2.8 KNN	13
2.2.9 IG dựa trên Entropy	14
2.2.10 Lựa chọn đặc trưng đa phương pháp và thêm đặc trưng tuần tự	14
2.2.11 SHAP	15
2.2.12 Các chỉ số đánh giá mô hình	16
2.2.13 Quá khớp và chiến lược chia dữ liệu	17

Chương 3.	Phương pháp nghiên cứu	18
3.1	Tổng quan hệ thống sản xuất hydrogen sinh học	18
3.2	Đầu vào, đầu ra và bài toán dự đoán	19
3.3	Các yếu tố đo được, cảm biến và đơn vị	19
3.4	Thiết bị thu thập dữ liệu cảm biến (DAQ)	20
3.5	Cách ước lượng HPR khi chưa dùng học máy	21
3.6	Vị trí của học máy trong quy trình	22
3.7	Tần suất thu thập dữ liệu và hiển thị dashboard	22
3.8	Quy trình dữ liệu và học máy	22
3.9	Lựa chọn đặc trưng đa phương pháp	23
3.10	Công cụ phần mềm	24
Chương 4.	Kết quả nghiên cứu và thảo luận	25
4.1	Mô tả dữ liệu	25
4.2	Phân tích tương quan giữa các đặc trưng	27
4.3	Tiền xử lý dữ liệu	28
4.4	Kết quả GRA	29
4.5	Xếp hạng bằng IG và hợp nhất thứ hạng	30
4.6	Phân tích đơn biến	32
4.7	So sánh hiệu suất mô hình	34
4.8	Thêm đặc trưng tuần tự từ top-3	35
4.9	Phân tích SHAP	37
4.10	Ý nghĩa sinh học của xếp hạng đặc trưng	38
4.11	Phân tích hiệu suất mô hình	39
4.12	Hiệu quả của lựa chọn đặc trưng	40
4.13	So sánh GRA, IG và SHAP	40
4.14	So sánh với nghiên cứu liên quan	41
4.15	Hạn chế	41
4.16	Hướng phát triển	42
Chương 5.	Kết luận	44
5.1	Đóng góp chính	44
5.2	Ý nghĩa thực tiễn	44
5.3	Bài học kinh nghiệm	45
5.4	Tổng kết	45
Phụ lục		46
Danh mục tài liệu tham khảo		47

DANH MỤC CÁC BẢNG, SƠ ĐỒ, HÌNH

Danh mục bảng

2.1	Tổng hợp một số nghiên cứu ứng dụng học máy trong năng lượng sinh học kỵ khí	9
3.1	Các yếu tố đo được, phương pháp/cảm biến đo và đơn vị.	20
4.1	Thông kê mô tả tập dữ liệu sau chuẩn hóa ($n = 197$)	25
4.2	Xếp hạng đặc trưng theo Grey Relational Grade	29
4.3	Thứ hạng tổng hợp từ GRA và IG	31
4.4	So sánh hiệu suất các mô hình ML trên tập kiểm tra (sai số quy về thang gốc, đơn vị L/h/L)	34
4.5	R^2 trên tập kiểm tra theo số đặc trưng (bắt đầu từ top-3 tổng hợp)	36
4.6	So sánh xếp hạng GRA, IG và SHAP (top-5)	38
5.1	Các hạng mục công việc thực hiện	46

Danh mục sơ đồ, hình

1.1	Nhu cầu hydro toàn cầu năm 2023 theo khu vực	2
1.2	Cơ cấu sản xuất hydrogen toàn cầu theo phương pháp	3
1.3	Các con đường trao đổi chất chính trong lên men tối	4
3.1	Sơ đồ quy trình hệ thống sản xuất hydrogen sinh học bằng lên men kỵ khí ở quy mô thử nghiệm.	18
3.2	Sơ đồ khối tổng quát của hệ thống và luồng dữ liệu.	21
4.1	Phân bố của các đặc trưng và biến mục tiêu sau chuẩn hóa	26
4.2	Biểu đồ hộp thể hiện phân tán và giá trị ngoại lai của các đặc trưng	27
4.3	Bản đồ nhiệt ma trận hệ số tương quan Pearson giữa 11 đặc trưng và HPR	28
4.4	Biểu đồ xếp hạng Grey Relational Grade của 11 đặc trưng	30
4.5	So sánh xếp hạng đặc trưng: IG (trái) và Grey Relational Grade (phải)	31
4.6	Phân tích đơn biến: quan hệ từng đặc trưng với HPR	33
4.7	So sánh hiệu suất các mô hình: (a) Hệ số R^2 , (b) MSE, (c) Biểu đồ phân tán giá trị dự đoán so với thực tế	34
4.8	Kết quả thêm đặc trưng tuần tự từ top-3: R^2 (trái) và MSE (phải) theo số đặc trưng	36
4.9	Đóng góp đặc trưng theo SHAP (trung bình $ SHAP $) cho mô hình tối ưu KNN	37

KÍ HIỆU CÁC CỤM TỪ VIẾT TẮT

Từ viết tắt	Giải thích
HPR	Hydrogen Production Rate - Tốc độ sản xuất hydro
GRA	Grey Relational Analysis - Phân tích quan hệ xám
ML	Machine Learning - Học máy
RF	Random Forest - Rừng ngẫu nhiên
KNN	K-Nearest Neighbors - K láng giềng gần nhất
DT	Decision Tree - Cây quyết định
SVR/SVM	Support Vector Regression/Machine
XGBoost	eXtreme Gradient Boosting
SHAP	SHapley Additive exPlanations
IG	Information Gain - Độ lợi thông tin
MI	Mutual Information - Thông tin tương hỗ
MSE	Mean Squared Error - Sai số bình phương trung bình
MAE	Mean Absolute Error - Sai số tuyệt đối trung bình
R^2	Coefficient of Determination - Hệ số xác định
HRT	Hydraulic Retention Time - Thời gian lưu thủy lực
ORP	Oxidation-Reduction Potential - Thế oxy hóa khử
VFA	Volatile Fatty Acids - Acid béo bay hơi
VSS	Volatile Suspended Solids - Chất rắn lơ lửng bay hơi
COD	Chemical Oxygen Demand - Nhu cầu oxy hóa học
OLR	Organic Loading Rate - Tải lượng hữu cơ
WWTP	Wastewater Treatment Plant - Nhà máy xử lý nước thải
GC	Gas Chromatography - Sắc ký khí
SMR	Steam Methane Reforming - Reforming khí metan bằng hơi nước
FCU	Feng Chia University - Đại học Phùng Giáp
IEA	International Energy Agency - Cơ quan Năng lượng Quốc tế
MCCA	Medium-Chain Carboxylic Acids - Acid carboxylic mạch trung bình

CHƯƠNG 1

GIỚI THIỆU


Chương này trình bày bối cảnh nghiên cứu, lý do chọn đề tài, đối tượng và phạm vi nghiên cứu, mục tiêu nghiên cứu, cùng cấu trúc tổng thể của khóa luận.

Khóa luận được triển khai trong khuôn khổ chương trình thực tập tài năng quốc tế TEEP do Bộ Giáo dục Đài Loan tài trợ, tại Đại học Phùng Giáp – nơi quy tụ một trong những nhóm nghiên cứu tiên phong về hydrogen sinh học tại Đài Loan. Đề tài được đồng hướng dẫn bởi Giáo sư Hsi-Min Chen (Khoa Kỹ thuật Thông tin và Khoa học Máy tính) và Giáo sư Chih-Hsin Shih (Khoa Kỹ thuật Hóa học), theo mô hình hợp tác liên ngành đang trở thành xu thế của khoa học hiện đại. Chính sự cộng hưởng giữa hai lĩnh vực – sức mạnh phân tích dữ liệu của trí tuệ nhân tạo và chiều sâu cơ chế của kỹ thuật hóa học – cho phép khóa luận không dừng lại ở việc dự đoán tốc độ tạo hydro, mà còn lý giải được bản chất sinh hóa đứng sau mỗi dự đoán.

1.1 Bối cảnh nghiên cứu

Nhu cầu năng lượng toàn cầu đang gia tăng nhanh chóng trong bối cảnh biến đổi khí hậu và cạn kiệt nhiên liệu hóa thạch. Theo báo cáo World Energy Outlook 2020 của Cơ quan Năng lượng Quốc tế, mặc dù nhu cầu năng lượng toàn cầu giảm khoảng 5% trong năm 2020 do đại dịch COVID-19, nhu cầu được dự báo tăng trưởng 9% trong giai đoạn 2019–2030 theo kịch bản Stated Policies Scenario [9]. Sự phụ thuộc vào nhiên liệu hóa thạch tiếp tục gây ra phát thải khí nhà kính ở mức cao, thúc đẩy nhu cầu cấp thiết về các nguồn năng lượng tái tạo sạch.

Trong bức tranh chuyển dịch năng lượng đó, hydrogen ngày càng được xem là một vật mang năng lượng then chốt. Theo báo cáo Global Hydrogen Review 2024 của IEA, nhu cầu hydrogen toàn cầu đã đạt khoảng 97 triệu tấn trong năm 2023 (tăng 2,5% so với năm 2022) và được dự báo tiệm cận 100 triệu tấn trong năm 2024 [10]. Tuy nhiên, phần lớn lượng hydrogen này hiện vẫn phục vụ các ứng dụng truyền thống như lọc dầu và sản xuất hóa chất như ammonia, methanol, trong khi tỷ trọng dành cho các ứng dụng năng lượng sạch mới (công nghiệp nặng, vận tải đường dài, lưu trữ năng lượng) còn chiếm chưa tới 1% tổng nhu cầu [10, 20]. Quan trọng hơn, đại đa số hydrogen ngày nay được sản xuất từ nhiên liệu hóa thạch chưa xử lý phát thải, khiến bản thân quá trình sản xuất hydrogen trở thành một nguồn phát thải đáng kể và đặt ra yêu cầu cấp thiết về các con đường sản xuất hydrogen sạch hơn. Nhu cầu này phân bố không đồng đều giữa các khu vực, với Trung Quốc và Hoa Kỳ là hai nước tiêu thụ lớn nhất (Hình 1.1).




Hình 1.1: Nhu cầu hydro toàn cầu năm 2023 theo khu vực (tổng khoảng 97 triệu tấn): Trung Quốc chiếm gần một phần ba, Hoa Kỳ khoảng 14%. Số liệu: IEA, *Global Hydrogen Review 2024* [10].

Trong số các nguồn năng lượng tái tạo, hydrogen sinh học nổi lên như một giải pháp tiềm năng nhờ đặc tính không phát thải carbon khi đốt cháy, mật độ năng lượng cao, và khả năng sản xuất từ nguồn biomass phong phú [3]. Hydrogen có nhiệt trị khối lượng cao nhất trong các nhiên liệu, khoảng 120 MJ/kg theo nhiệt trị thấp và 142 MJ/kg theo nhiệt trị cao — gấp khoảng ba lần khí methane và cao hơn nhiều so với xăng (44 MJ/kg) hay diesel (45 MJ/kg) — trong khi sản phẩm cháy duy nhất là nước. Vì vậy, hydrogen được xem là một trong những trụ cột của quá trình chuyển dịch năng lượng hướng tới mục tiêu trung hòa carbon. Sản xuất hydrogen sinh học từ sinh khối còn có ý nghĩa kép: vừa tạo ra nhiên liệu sạch, vừa góp phần xử lý chất thải hữu cơ, do đó tiếp tục thu hút sự quan tâm nghiên cứu cho cả hiện tại lẫn tương lai [23].


Để định vị hydrogen sinh học trong bức tranh chung, các phương pháp sản xuất hydrogen thường được phân loại theo “phổ màu” phản ánh nguồn năng lượng và mức phát thải carbon kèm theo [25]. *Hydrogen xám* được sản xuất bằng reforming khí metan với CO₂ thải thẳng ra khí quyển và hiện chiếm phần lớn sản lượng hydrogen toàn cầu; *hydrogen lam* cũng dùng SMR nhưng kết hợp thu giữ và lưu trữ carbon; *hydrogen lục* được tạo ra bằng điện phân nước sử dụng điện tái tạo. Trong khi đó, hydrogen sinh học sản xuất bằng con đường sinh học từ sinh khối được một số nghiên cứu gần đây xếp vào nhóm phát thải thấp nhất, thậm chí có thể đạt cân bằng carbon âm khi tận dụng chất thải hữu cơ làm nguyên liệu [25, 20]. Vị trí này khiến hydrogen sinh học trở thành một hướng đi đáng quan tâm trong nỗ lực “làm sạch” chính khâu sản xuất hydrogen.

Thực trạng cơ cấu sản xuất hydrogen hiện nay được minh họa trong Hình 1.2: phần lớn hydrogen vẫn đến từ các nguồn hóa thạch — reforming khí metan chiếm khoảng 49%, reforming dầu khoảng 29% và khí hóa than khoảng 17% — trong khi điện phân nước chỉ đóng góp khoảng 4%. Bức tranh này cho thấy dư địa rất lớn cho các con đường sản xuất hydrogen phát thải thấp, trong đó có hydrogen sinh học từ lên men kỵ khí.



Hình 1.2: Cơ cấu sản xuất hydrogen toàn cầu theo phương pháp, cho thấy ưu thế áp đảo của các nguồn hóa thạch (SMR, reforming dầu, khí hóa than). Nguồn: Wikimedia Commons, tác giả Alexpreeves, giấy phép CC BY-SA 4.0; số liệu gốc theo Dincer & Acar (2015).

Quá trình lên men tối là một trong những phương pháp sản xuất hydrogen sinh học được quan tâm nhất, trong đó vi sinh vật kỵ khí chuyển hóa cơ chất hữu cơ thành khí H_2 và các acid hữu cơ. So với các phương pháp sản xuất hydrogen khác như điện phân nước hay reforming khí tự nhiên, lên men tối có ưu điểm vận hành liên tục và ổn định, không phụ thuộc vào điều kiện thời tiết như năng lượng mặt trời hay gió, đồng thời có thể tận dụng đa dạng chất thải hữu cơ làm nguyên liệu đầu vào [3]. Hiệu suất của lên men tối phụ thuộc mạnh vào các thông số vận hành (pH, nhiệt độ, thời gian lưu, tải lượng hữu cơ) cũng như đặc tính của cơ chất và sản phẩm phụ [7]. Một thách thức cố hữu là hiệu suất chuyển hóa thực tế thấp hơn nhiều so với giới hạn lý thuyết: con đường lên men theo hướng acetate có thể đạt tối đa khoảng 4 mol H_2 trên mỗi mol glucose, trong khi con đường butyrate chỉ cho khoảng 2 mol H_2 [24]. Do sự cạnh tranh giữa các con đường trao đổi chất và hoạt động của các vi sinh vật tiêu thụ hydrogen, cân bằng electron giữa các sản phẩm trung gian (đặc biệt là tỷ lệ giữa acetate và các chất khác) có liên hệ chặt chẽ với hiệu suất và tốc độ sinh hydrogen [15]. Hình 1.3 minh họa đơn giản hóa các con đường trao đổi chất chính của quá trình này.



Hình 1.3: Sơ đồ đơn giản hóa các con đường trao đổi chất chính trong lên men tối từ sucrose. Con đường acetate cho năng suất hydro lý thuyết cao nhất (4 mol H_2 /mol glucose), con đường butyrate cho 2 mol, trong khi con đường propionate tiêu thụ hydro. Phỏng theo Rittmann & Herwig (2012) [24] và Liu và cộng sự (2020) [15].

Đài Loan, với ngành công nghiệp đường mía phát triển, có lợi thế đáng kể trong việc sử dụng sucrose làm cơ chất cho quá trình lên men tối. Đặc biệt, nhóm nghiên cứu hydrogen sinh học tại Đại học Phùng Giáp đã xây dựng và vận hành thành công hệ thống lên men kỵ khí quy mô thử nghiệm sử dụng sucrose, với hệ thống quy mô thử nghiệm 400 L vận hành ở 35 °C và tải lượng hữu cơ tới 240 kg COD/m³/ngày, đạt tốc độ sinh hydrogen cực đại khoảng 15 L/h/L [14]. Các nghiên cứu tiếp nối tại FCU tiếp tục khẳng định tính khả thi của hướng tiếp cận này [13, 29]. Bộ dữ liệu sử dụng trong khóa luận được thu thập từ một hệ thống reactor quy mô thử nghiệm thuộc cùng nhóm nghiên cứu FCU.

Tuy nhiên, tốc độ tạo hydro trong hệ thống lên men kỵ khí chịu ảnh hưởng đồng thời của nhiều yếu tố sinh hóa phức tạp như pH, nồng độ acid béo bay hơi, thế oxy hóa khử, và nồng độ vi sinh vật. Mối quan hệ phi tuyến giữa các yếu tố này khiến việc tối ưu hóa vận hành bể phản ứng sinh học trở nên khó khăn khi chỉ dựa vào phương pháp thí nghiệm truyền thống [19].

Trong bối cảnh đó, học máy đã chứng minh khả năng mô hình hóa các mối quan hệ phi tuyến phức tạp trong hệ thống sinh học. Nhiều nghiên cứu gần đây đã áp dụng thành công các thuật toán ML để dự đoán hiệu suất của quá trình lên men kỵ khí [8, 19]. Tuy nhiên, phần lớn các nghiên cứu hiện có tập trung vào việc xây dựng mô hình dự đoán mà chưa chú trọng đầy đủ đến việc lựa chọn đặc trưng có hệ thống và giải thích mô hình.

1.2 Lý do chọn đề tài

Quá trình lên men tối sản xuất hydrogen sinh học bị chi phối bởi nhiều yếu tố vận hành và sinh hóa tương tác phức tạp. Việc tiến hành thí nghiệm để khảo sát ảnh hưởng của từng yếu tố đòi hỏi thời gian dài, chi phí cao, và khó kiểm soát đồng thời tất cả các biến số. Một mô hình dự đoán dựa trên dữ liệu có thể giúp giảm đáng kể chi phí thí nghiệm và hỗ trợ ra quyết định vận hành bể phản ứng sinh học.

Các nghiên cứu hiện có về dự đoán HPR bằng ML [8, 19] thường sử dụng toàn bộ đặc trưng có sẵn mà không đánh giá mức độ ảnh hưởng tương đối của từng yếu tố. Điều này dẫn đến hai hạn chế: (1) mô hình có thể bị nhiễu bởi các đặc trưng ít liên quan, và (2) thiếu thông tin hướng dẫn cho kỹ sư vận hành về yếu tố nào cần ưu tiên kiểm soát.

Nghiên cứu này đề xuất một quy trình kết hợp Grey Relational Analysis [5] để xếp hạng mức độ ảnh hưởng của các đặc trưng trước khi huấn luyện mô hình, sau đó sử dụng phương pháp thêm đặc trưng tuần tự để xác định tổ hợp đặc trưng tối ưu, và cuối cùng áp dụng SHAP [17] để giải thích kết quả dự đoán. Cách tiếp cận này kết hợp phân tích trước huấn luyện và sau huấn luyện, cung cấp cái nhìn toàn diện về vai trò của từng yếu tố sinh hóa đối với HPR.

1.3 Đối tượng và phạm vi nghiên cứu

1.3.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của khóa luận là tốc độ tạo hydro (HPR, đơn vị L/h/L) trong hệ thống lên men kỵ khí sử dụng sucrose làm cơ chất, vận hành ở quy mô thử nghiệm tại Đại học Phùng Giáp, Đài Trung, Đài Loan.

1.3.2 Phạm vi nghiên cứu

Phạm vi nghiên cứu được giới hạn như sau:

- **Dữ liệu:** 11 đặc trưng sinh hóa đầu vào bao gồm pH, VSS, ethanol, acetate, propionate, butyrate, sucrose degradation, ORP_{mid} , ORP_{low} , VFA, và COD_o .
- **Thuật toán ML:** 5 thuật toán được khảo sát gồm Random Forest, XGBoost, Decision Tree, K-Nearest Neighbors, và Support Vector Regression.
- **Phương pháp đánh giá đặc trưng:** GRA (trước huấn luyện) và SHAP (sau huấn luyện).
- **Phạm vi thời gian:** Dữ liệu thu thập từ hệ thống reactor vận hành liên tục trong khoảng hơn hai tháng (giai đoạn 19/03–26/05/2026), với 197 mẫu quan sát cách nhau trung vị khoảng 8 giờ.

1.4 Mục tiêu nghiên cứu

1.4.1 Mục tiêu tổng quát

Xây dựng mô hình học máy dự đoán tốc độ tạo hydro trong hệ thống lên men kỵ khí, đồng thời xác định và giải thích vai trò của các yếu tố sinh hóa ảnh hưởng đến HPR.

1.4.2 Mục tiêu cụ thể

Mục tiêu 1: Áp dụng GRA để xếp hạng mức độ ảnh hưởng của 11 đặc trưng sinh hóa đối với HPR.

Mục tiêu 2: Xây dựng và so sánh hiệu suất của 5 mô hình ML gồm RF, XGBoost, DT, KNN, SVR trong việc dự đoán HPR.

Mục tiêu 3: Xác định tổ hợp đặc trưng tối ưu thông qua phương pháp thêm đặc trưng tuần tự dựa trên thứ hạng tổng hợp GRA và IG.

Mục tiêu 4: Giải thích mô hình dự đoán tốt nhất bằng phương pháp SHAP và so sánh kết quả với xếp hạng GRA.

1.5 Câu hỏi nghiên cứu

Để đạt được các mục tiêu nêu trên, khóa luận tập trung trả lời bốn câu hỏi nghiên cứu sau:

Câu hỏi 1: Trong số 11 đặc trưng sinh hóa được khảo sát, những yếu tố nào có mức độ tương quan mạnh nhất với tốc độ tạo hydro, và thứ tự ảnh hưởng của chúng được xác định như thế nào bằng GRA?

Câu hỏi 2: Trong năm thuật toán học máy được khảo sát, thuật toán nào cho hiệu suất dự đoán HPR tốt nhất trên tập dữ liệu quy mô thử nghiệm, và sự khác biệt về hiệu suất phản ánh điều gì về bản chất của dữ liệu?

Câu hỏi 3: Việc lựa chọn đặc trưng theo thứ hạng tổng hợp GRA và IG có giúp cải thiện hoặc duy trì hiệu suất mô hình so với việc sử dụng toàn bộ đặc trưng hay không, và tổ hợp đặc trưng tối thiểu cần thiết là bao nhiêu?

Câu hỏi 4: Kết quả giải thích mô hình bằng SHAP (sau huấn luyện) có nhất quán với xếp hạng GRA (trước huấn luyện) hay không, và sự khác biệt (nếu có) mang ý nghĩa gì về mối quan hệ giữa các đặc trưng và HPR?

1.6 Ý nghĩa khoa học và thực tiễn

1.6.1 Ý nghĩa khoa học

Về mặt khoa học, khóa luận đóng góp một quy trình phân tích đặc trưng tích hợp, kết hợp phương pháp GRA (đánh giá trước huấn luyện) và phương pháp SHAP (giải thích sau huấn luyện). Cách tiếp cận song song này cho phép đối chiếu giữa mức độ tương quan thống kê của từng đặc trưng và đóng góp thực tế của chúng trong mô hình phi tuyến đã học, qua đó cung cấp cái nhìn đa chiều về vai trò của các yếu tố sinh hóa. Việc gắn kết kết quả mô hình hóa dữ liệu với cơ chế sinh học của quá trình lên men tối cũng góp phần thu hẹp khoảng cách giữa hai lĩnh vực kỹ thuật dữ liệu và công nghệ sinh học môi trường.

1.6.2 Ý nghĩa thực tiễn

Về mặt thực tiễn, mô hình dự đoán HPR dựa trên dữ liệu giúp giảm nhu cầu tiến hành các thí nghiệm thăm dò tốn kém và mất thời gian khi vận hành bể phản ứng sinh học. Kết quả xếp hạng đặc trưng cung cấp thông tin định hướng cho kỹ sư vận hành về những thông số cần ưu tiên giám sát và kiểm soát. Hơn nữa, nếu chỉ cần một số ít đặc trưng quan trọng đã đủ để dự đoán HPR với độ chính xác chấp nhận được, chi phí phân tích mẫu và lắp đặt cảm biến trong thực tế sản xuất có thể được cắt giảm đáng kể.

1.7 Cấu trúc báo cáo

Khóa luận được tổ chức thành 5 chương với nội dung như sau:

Chương 1 – Giới thiệu: Trình bày bối cảnh nghiên cứu, lý do chọn đề tài, đối tượng và phạm vi, mục tiêu nghiên cứu, và cấu trúc báo cáo.

Chương 2 – Cơ sở lý thuyết: Trình bày tổng quan các nghiên cứu liên quan, nền tảng lý thuyết về sản xuất hydrogen sinh học, các yếu tố ảnh hưởng HPR, GRA, IG, các thuật toán ML được sử dụng, và SHAP.

Chương 3 – Phương pháp nghiên cứu: Mô tả hệ thống sản xuất hydrogen, đầu vào – đầu ra, các yếu tố đo được cùng cảm biến và đơn vị, cách ước lượng HPR khi chưa dùng học máy, vị trí của học máy trong quy trình, cơ chế thu thập dữ liệu và dashboard, và quy trình học máy với lựa chọn đặc trưng đa phương pháp.

Chương 4 – Kết quả nghiên cứu và thảo luận: Trình bày kết quả phân tích dữ liệu, xếp hạng GRA và IG, so sánh mô hình, thêm đặc trưng tuần tự từ top-3, và phân tích SHAP; đồng thời thảo luận ý nghĩa sinh học, so sánh với các nghiên cứu liên quan, đánh giá hạn chế và đề xuất hướng phát triển.

Chương 5 – Kết luận: Tổng kết đóng góp chính, ý nghĩa thực tiễn, và bài học kinh nghiệm.

CHƯƠNG 2

CƠ SỞ LÝ THUYẾT

Chương này trình bày tổng quan các nghiên cứu liên quan, cơ sở lý thuyết về sản xuất hydrogen sinh học, các yếu tố ảnh hưởng đến HPR, phương pháp GRA, các thuật toán học máy được sử dụng, và phương pháp giải thích mô hình SHAP.

2.1 Tổng quan các nghiên cứu liên quan

Việc ứng dụng học máy vào lĩnh vực năng lượng sinh học kỵ khí đã phát triển nhanh trong những năm gần đây. Phần này điểm lại một số hướng nghiên cứu tiêu biểu nhằm xác định khoảng trống mà khóa luận hướng đến giải quyết.

2.1.1 Học máy trong dự đoán hiệu suất lên men kỵ khí

Trong lĩnh vực đồng phân hủy sinh khối, Pei và cộng sự nghiên cứu quá trình đồng phân hủy sinh khối lignocellulose với phân động vật nhằm khảo sát tương tác giữa các loài vi sinh vật và cấu trúc của các hốc sinh thái [22]. Ở hướng sản xuất acid carboxylic mạch trung bình từ rác thải thực phẩm, Long và cộng sự đã tích hợp học máy vào quy trình và đạt được mức tăng sản lượng đáng kể so với quy mô phòng thí nghiệm, với các mô hình dự đoán cho sai số RMSE thấp và hệ số xác định cao [16].

Đối với bài toán sản xuất hydrogen sinh học, Hosseinzadeh và cộng sự xây dựng mô hình học máy (bao gồm mạng nơ-ron nhân tạo) để dự đoán và phân tích quá trình sản xuất hydrogen sinh học từ nước thải bằng lên men tối, đồng thời sử dụng quy trình đánh giá tầm quan trọng biến số bằng hoán vị để nhận diện các yếu tố then chốt [8]. Pandey và cộng sự tổng hợp một cách hệ thống các ứng dụng, ưu điểm và thách thức của học máy trong sản xuất hydrogen sinh học bằng lên men, nhấn mạnh tính phức tạp và phi tuyến cao của dữ liệu sinh học [19].

Trong lĩnh vực sản xuất biogas/methane từ phân hủy kỵ khí, một số nghiên cứu gần đây kết hợp học máy với các kỹ thuật tối ưu hóa và xử lý dữ liệu. Wang và cộng sự đề xuất mô hình kết hợp dựa trên hồi quy RF để dự đoán hiệu suất methane trong phân hủy kỵ khí sinh khối lignocellulose [31]. Ahmad và cộng sự kết hợp học máy với phương pháp bề mặt đáp ứng để dự đoán và tối ưu tiềm năng biogas của sinh khối [1]. Các nghiên cứu này cho thấy mô hình dạng cây và phương pháp ensemble được sử dụng rộng rãi và thường cho hiệu suất tốt trên dữ liệu quá trình sinh học.

Bảng 2.1 tóm tắt một số nghiên cứu tiêu biểu về ứng dụng học máy trong lĩnh vực năng lượng sinh học kỵ khí.

Bảng 2.1: Tổng hợp một số nghiên cứu ứng dụng học máy trong năng lượng sinh học kỵ khí

Nghiên cứu	Đối tượng	Phương pháp ML	Trọng tâm
Pei và cs. [22]	Đồng phân hủy biogas	Extreme Learning Machine	Tương tác loài và cấu trúc cộng đồng vi sinh
Long và cs. [16]	MCCA từ rác thực phẩm	Nhiều mô hình ML	Tối ưu sản lượng acid mạch trung bình
Hosseinzadeh và cs. [8]	Biohydrogen từ nước thải	ANN và mô hình ML	Dự đoán và đánh giá tầm quan trọng biến số
Pandey và cs. [19]	Biohydrogen lên men	Tổng quan ML	Ưu điểm, thách thức, ứng dụng
Wang và cs. [31]	Methane từ lignocellulose	RF kết hợp	Dự đoán hiệu suất methane
Ahmad và cs. [1]	Tiềm năng biogas	ML kết hợp RSM	Dự đoán và tối ưu sản lượng biogas


2.1.2 Khoảng trống nghiên cứu

Qua khảo sát các nghiên cứu trên có thể nhận thấy hai điểm chung: (1) phần lớn nghiên cứu tập trung xây dựng mô hình dự đoán với độ chính xác cao nhưng chưa thực hiện đánh giá có hệ thống mức độ ảnh hưởng tương đối của từng đặc trưng trước khi huấn luyện; và (2) khâu giải thích mô hình thường được thực hiện độc lập, ít khi đối chiếu giữa phương pháp trước huấn luyện và sau huấn luyện. Khóa luận này hướng đến lấp khoảng trống đó bằng cách kết hợp GRA (đánh giá trước huấn luyện) với SHAP (giải thích sau huấn luyện) trong cùng một quy trình, áp dụng cho dữ liệu sản xuất hydrogen từ sucrose ở quy mô thử nghiệm.

2.2 Cơ sở lý thuyết

2.2.1 Sản xuất hydrogen sinh học bằng lên men tối


Hydrogen sinh học được sản xuất thông qua quá trình lên men tối, trong đó vi sinh vật kỵ khí chuyển hóa cơ chất hữu cơ thành khí H_2 , CO_2 , và các acid hữu cơ trong điều kiện không có ánh sáng [3]. Phản ứng tổng quát khi sử dụng glucose làm cơ chất:



Các ưu điểm chính của lên men tối so với các phương pháp sản xuất hydrogen khác bao gồm: (1) vận hành liên tục và ổn định, không phụ thuộc vào điều kiện thời tiết như năng lượng mặt trời hay gió; (2) có thể sử dụng đa dạng cơ chất bao gồm sucrose, glucose, và chất thải hữu cơ; (3) tốc độ sản xuất hydrogen cao hơn so với quá trình quang hợp sinh học [13].

Trong quá trình lên men, cơ chất carbohydrate được phân giải qua con đường glycolysis

thành pyruvate, sau đó tiếp tục chuyển hóa theo các con đường khác nhau tùy điều kiện môi trường và quần thể vi sinh vật. Hai con đường sản xuất hydrogen chính gắn liền với sản phẩm acetate và butyrate. Theo lý thuyết, con đường acetate cho hiệu suất cao nhất với 4 mol H₂ trên mỗi mol glucose, trong khi con đường butyrate cho 2 mol H₂ trên mỗi mol glucose [7]. Con đường acetate ứng với phản ứng (2.1) đã nêu ở trên, còn con đường butyrate được biểu diễn như sau:



Ngược lại, các con đường tạo propionate hoặc lactate được xem là con đường tiêu thụ hydrogen hoặc không sinh hydrogen, làm giảm hiệu suất tổng thể. Vì vậy, sự phân bố giữa các sản phẩm trao đổi chất phản ánh trực tiếp định hướng của hệ lên men: hệ thiên về acetate–butyrate thường có hiệu suất hydrogen cao, trong khi hệ tích lũy propionate cho hiệu suất thấp [15]. Trên thực tế, hiệu suất hydrogen thường thấp hơn giá trị lý thuyết do một phần electron bị chuyển sang sinh khối tế bào và các sản phẩm khử khác, cũng như do hoạt động của vi sinh vật tiêu thụ hydrogen [7].

Các sản phẩm phụ chính của quá trình lên men tối bao gồm butyrate, acetate, propionate, và ethanol. Tỷ lệ giữa các sản phẩm phụ này phản ánh con đường trao đổi chất đang diễn ra và có mối liên hệ trực tiếp với hiệu suất sản xuất hydrogen [6]. Việc cân bằng electron giữa các sản phẩm trung gian là một chỉ thị quan trọng để đánh giá và tối ưu quá trình [15].

2.2.2 Các yếu tố ảnh hưởng đến HPR

Tốc độ tạo hydro trong hệ thống lên men kỵ khí chịu ảnh hưởng của nhiều yếu tố sinh hóa và vận hành tương tác phức tạp. Các phân tích tổng hợp dữ liệu từ nhiều nghiên cứu cho thấy hiệu suất quá trình phụ thuộc đồng thời vào các thông số vận hành như pH, nhiệt độ, thời gian lưu thủy lực, tải lượng hữu cơ và loại cơ chất, khiến việc xác định điều kiện tối ưu chung trở nên khó khăn [18, 7]. Dưới đây là phân tích vai trò của các yếu tố chính được sử dụng làm đặc trưng trong nghiên cứu:

pH: Là yếu tố quan trọng nhất ảnh hưởng đến hoạt động của vi sinh vật kỵ khí. Quá trình acid hóa do tích lũy VFA có thể ức chế phản ứng sản xuất hydrogen. Khoảng pH tối ưu cho lên men tối thường nằm trong vùng trung tính đến acid yếu (5.5–6.5) [13]. pH không chỉ ảnh hưởng đến hoạt tính enzyme mà còn quyết định cấu trúc quần thể vi sinh vật: pH điều khiển sự cân bằng giữa các nhóm vi khuẩn sinh hydrogen và các nhóm cạnh tranh, qua đó định hướng con đường trao đổi chất chủ đạo trong hệ [28].

Thế oxy hóa khử: ORP là chỉ thị quan trọng phản ánh trạng thái oxy hóa khử của môi trường lên men. Trong quá trình lên men, ORP giảm ở giai đoạn thủy phân do sự giải phóng electron, sau đó tăng trở lại ở giai đoạn sinh acid do quá trình hấp thu electron trong chuyển hóa tạo acid. Vì vậy, biến thiên của ORP có thể được dùng làm chỉ thị cho tiến trình lên men kỵ khí, đồng thời phản ánh sự thay đổi pH và có tương quan thống

kê với nồng độ acetate trong hệ [29]. Mối quan hệ giữa ORP và HPR thường phức tạp và phi tuyến hơn so với các đặc trưng khác do ORP thay đổi liên tục theo các giai đoạn phản ứng.

Butyrate: Con đường trao đổi chất từ glucose sang butyrate là con đường chính sản xuất H_2 , vì các metabolite trung gian chứa nhiều nguyên tử hydrogen. Tuy nhiên, nồng độ butyrate quá cao có thể gây ức chế ngược đối với vi sinh vật sản xuất hydrogen [6].

VSS: Đại diện cho nồng độ vi sinh vật trong hệ thống, là thông số cơ bản cho thiết kế và kiểm soát quá trình xử lý sinh học. VSS cao cho thấy mật độ vi sinh vật lớn, có thể tăng tốc độ chuyển hóa cơ chất [13].

VFA: Tổng nồng độ acid béo bay hơi phản ánh mức độ acid hóa của hệ thống. VFA bao gồm acetate, propionate, và butyrate. Nồng độ VFA quá cao dẫn đến giảm pH và ức chế vi sinh vật [30].

Propionate: Là sản phẩm của con đường trao đổi chất tiêu thụ hydrogen. Nồng độ propionate cao cho thấy hydrogen đang bị tiêu thụ thay vì được giải phóng dưới dạng khí.

Ethanol: Là sản phẩm phụ dạng dung môi, có thể ức chế một số loài vi khuẩn sản xuất hydrogen ở nồng độ cao.

COD: Phản ánh tải lượng hữu cơ đầu vào. Tải lượng hữu cơ ảnh hưởng đến pH, nồng độ ammonia, và VFA. OLR quá cao có thể dẫn đến tích lũy ammonia, ức chế vi khuẩn methanogenic [11].

2.2.3 GRA

GRA là phương pháp phân tích đa yếu tố thuộc lý thuyết hệ xám, được đề xuất bởi Deng [5]. Phương pháp này đánh giá mức độ tương quan, cường độ, và thứ tự ảnh hưởng của các yếu tố đến biến mục tiêu. Ưu điểm của GRA là không giới hạn cỡ mẫu và không yêu cầu dữ liệu tuân theo phân phối chuẩn [32, 33].

Quy trình thực hiện GRA gồm các bước sau:

Bước 1 – Xác định chuỗi tham chiếu và chuỗi so sánh: Chuỗi tham chiếu là biến mục tiêu HPR, ký hiệu $x_0(k)$. Các chuỗi so sánh là 11 đặc trưng đầu vào, ký hiệu $x_i(k)$ với $i = 1, 2, \dots, 11$.

Bước 2 – Tiền xử lý chuỗi: Mỗi chuỗi được chuẩn hóa bằng cách chia cho giá trị trung bình:

$$x_i^*(k) = \frac{x_i(k)}{\bar{x}_i} \quad (2.3)$$

trong đó $\bar{x}_i$ là giá trị trung bình của chuỗi x_i .

Bước 3 – Tính hệ số tương quan xám:

$$\gamma_{0,i}(k) = \frac{\Delta_{\min} + \xi \Delta_{\max}}{\Delta_{0,i}(k) + \xi \Delta_{\max}} \quad (2.4)$$

trong đó $\Delta_{0,i}(k) = |x_0^*(k) - x_i^*(k)|$ là độ lệch tuyệt đối, $\Delta_{\min}$ và $\Delta_{\max}$ lần lượt là giá trị nhỏ

nhất và lớn nhất của tất cả $\Delta_{0,i}(k)$, và $\xi \in (0, 1]$ là hệ số phân biệt, thường chọn $\xi = 0.5$ [5].

Bước 4 – Tính grey relational grade:

$$\Gamma_{0,i} = \frac{1}{n} \sum_{k=1}^n \gamma_{0,i}(k) \quad (2.5)$$

trong đó n là số quan sát trong chuỗi.

Bước 5 – Xếp hạng: Các đặc trưng được xếp hạng theo grey relational grade giảm dần. Grade cao hơn cho thấy mức độ tương quan mạnh hơn với HPR, tức yếu tố đó có ảnh hưởng lớn hơn đến biến mục tiêu.

2.2.4 SVR

SVM là thuật toán học máy tìm siêu phẳng tối ưu để phân tách dữ liệu; biến thể dùng cho bài toán hồi quy được gọi là SVR. SVR tìm hàm $f(x)$ sao cho sai số không vượt quá ngưỡng ε cho trước, đồng thời tối thiểu hóa độ phức tạp của mô hình [27, 21].

SVR sử dụng hàm mất mát ε -insensitive, theo đó những sai lệch nhỏ hơn ε không bị phạt; chỉ những điểm nằm ngoài “ống” có bán kính ε mới đóng góp vào hàm mất mát. Bài toán tối ưu của SVR tuyến tính được phát biểu như sau [27]:

$$\min_{w,b,\xi,\xi^*} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \quad (2.6)$$

với ràng buộc $y_i - \langle w, x_i \rangle - b \leq \varepsilon + \xi_i$, $\langle w, x_i \rangle + b - y_i \leq \varepsilon + \xi_i^*$, và $\xi_i, \xi_i^* \geq 0$. Trong đó C là tham số chính quy hóa kiểm soát sự đánh đổi giữa độ phẳng của hàm và mức độ chấp nhận sai số, còn ξ_i, ξ_i^* là các biến nới lỏng.

Đối với bài toán phi tuyến, SVR sử dụng kernel trick để ánh xạ dữ liệu vào không gian đặc trưng chiều cao hơn, nơi mối quan hệ trở nên tuyến tính. Các kernel phổ biến bao gồm RBF, polynomial, và sigmoid [27]. SVR phù hợp cho các bài toán có số chiều cao và cỡ mẫu vừa phải, nhưng nhạy cảm với việc lựa chọn tham số C , ε và tham số kernel.

2.2.5 DT

DT là thuật toán học máy có cấu trúc cây phân nhánh, trong đó mỗi nút nội biểu diễn một điều kiện phân chia dựa trên một đặc trưng, và mỗi nút lá cho ra giá trị dự đoán. Trong bài toán hồi quy, giá trị tại mỗi nút lá là trung bình của các mẫu thuộc nút đó.

Ưu điểm của DT là dễ hiểu và trực quan, có thể xử lý cả dữ liệu số và phân loại. Tuy nhiên, nhược điểm chính là dễ bị quá khớp khi cây quá sâu hoặc khi số lượng đặc trưng lớn.

2.2.6 RF

RF là phương pháp ensemble kết hợp nhiều DT được huấn luyện độc lập bằng kỹ thuật bootstrap sampling [2]. Mỗi cây trong rừng được xây dựng trên một tập con ngẫu nhiên của dữ liệu huấn luyện, và tại mỗi nút phân chia, chỉ một tập con ngẫu nhiên gồm m đặc trưng (với $m < M$, M là tổng số đặc trưng) được xem xét.

Kết quả dự đoán cuối cùng là trung bình đầu ra của tất cả các cây trong rừng:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T h_t(x) \quad (2.7)$$

trong đó T là số cây và $h_t(x)$ là dự đoán của cây thứ t .

Breiman [2] chứng minh rằng sai số tổng quát hóa của RF hội tụ khi số cây tăng, và phụ thuộc vào sức mạnh của từng cây và mức độ tương quan giữa các cây. RF có ưu điểm giảm quá khớp so với DT đơn lẻ, ít nhạy với nhiễu và giá trị ngoại lai, và yêu cầu ít siêu tham số cần tinh chỉnh.

2.2.7 XGBoost

XGBoost là framework gradient boosting hiệu suất cao được đề xuất bởi Chen và Guestrin [4]. Khác với RF xây dựng các cây độc lập, XGBoost xây dựng các cây tuần tự, trong đó mỗi cây mới được huấn luyện để giảm thiểu phần dư của các cây trước đó.

Hàm mục tiêu tại vòng lặp thứ t :

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (2.8)$$

trong đó l là hàm mất mát, f_t là cây mới được thêm vào, và $\Omega(f_t)$ là số hạng chính quy hóa kiểm soát độ phức tạp của cây.

XGBoost so sánh information gain trước khi thêm nhánh mới (khác với RF chọn ngẫu nhiên), giúp đạt độ chính xác cao hơn. Ưu điểm của XGBoost bao gồm: xử lý giá trị ngoại lai tốt nhờ tối ưu hóa dựa trên gradient, hiệu quả với tập dữ liệu lớn và phức tạp, và có cơ chế chính quy hóa tích hợp để tránh quá khớp [4].

2.2.8 KNN

KNN là thuật toán instance-based learning, dự đoán giá trị đầu ra bằng cách tìm K điểm dữ liệu gần nhất trong tập huấn luyện và lấy trung bình giá trị của chúng:

$$\hat{y} = \frac{1}{K} \sum_{i=1}^K y_{(i)} \quad (2.9)$$

trong đó $y_{(i)}$ là giá trị mục tiêu của điểm láng giềng thứ i .

Khoảng cách thường được tính bằng Euclidean distance. Giá trị K thường được chọn là số lẻ để tránh trường hợp hòa. Ưu điểm của KNN là đơn giản và hiệu quả tính toán khi tập dữ liệu nhỏ. Nhược điểm chính là nhạy cảm với thang đo của đặc trưng, do đó cần chuẩn hóa dữ liệu trước khi áp dụng.

2.2.9 IG dựa trên Entropy

Bên cạnh GRA, nghiên cứu sử dụng một phương pháp xếp hạng đặc trưng độc lập dựa trên lý thuyết thông tin của Shannon [26], nhằm tăng độ tin cậy của kết quả lựa chọn đặc trưng. Khái niệm trung tâm là *entropy*, đo mức độ bất định của một biến ngẫu nhiên Y :

$$H(Y) = - \sum_y p(y) \log p(y) \quad (2.10)$$

trong đó $p(y)$ là xác suất của giá trị y . Entropy càng lớn thì biến càng khó dự đoán.

Information Gain của một đặc trưng X đối với biến mục tiêu Y chính là lượng thông tin tương hỗ:

$$IG(Y, X) = I(X; Y) = H(Y) - H(Y | X) \quad (2.11)$$

nghĩa là mức giảm bất định của Y khi đã biết X . Giá trị IG càng cao cho thấy đặc trưng mang càng nhiều thông tin về HPR. Khác với hệ số tương quan tuyến tính, MI nắm bắt được cả các quan hệ phi tuyến và không yêu cầu giả định về dạng phân phối [12].

Do HPR là biến liên tục, nghiên cứu ước lượng MI bằng phương pháp dựa trên khoảng cách tới k láng giềng gần nhất của Kraskov và cộng sự [12], được hiện thực trong hàm `mutual_info_regression` của thư viện `scikit-learn` [21]. Phương pháp này không phân chia dữ liệu thành các khoảng rời rạc nên phù hợp với dữ liệu sinh hóa liên tục và cỡ mẫu vừa phải.

So với GRA, IG đại diện cho một góc nhìn xếp hạng khác: GRA đo mức độ tương đồng về hình dạng giữa chuỗi đặc trưng và chuỗi mục tiêu sau khi chuẩn hóa, trong khi IG đo lượng thông tin (mức giảm bất định) mà đặc trưng đóng góp. Việc sử dụng đồng thời hai phương pháp cho phép kiểm chứng chéo về tầm quan trọng của đặc trưng: những đặc trưng được cả hai phương pháp xếp hạng cao có độ tin cậy lớn hơn.

2.2.10 Lựa chọn đặc trưng đa phương pháp và thêm đặc trưng tuần tự

Lựa chọn đặc trưng là một họ phương pháp; GRA, IG và thêm đặc trưng tuần tự chỉ là một số cách tiếp cận trong đó. Nghiên cứu này kết hợp chúng theo một quy trình ba bước nhằm tận dụng ưu điểm của từng phương pháp.

Bước 1 – Xếp hạng bằng hai phương pháp độc lập: Tính grey relational grade và IG cho cả 11 đặc trưng, thu được hai bảng xếp hạng.

Bước 2 – Hợp nhất xếp hạng: Với mỗi đặc trưng, lấy trung bình thứ hạng từ hai phương pháp để tạo *thứ hạng tổng hợp*. Cách hợp nhất theo thứ hạng ít nhạy cảm với

chênh lệch thang đo giữa grey relational grade và MI.

Bước 3 – Thêm đặc trưng tuần tự bắt đầu từ top-3: Bắt đầu với ba đặc trưng mạnh nhất theo thứ hạng tổng hợp, sau đó lần lượt thêm từng đặc trưng tiếp theo (thứ tư, thứ năm, ..., thứ mười một). Sau mỗi lần thêm, huấn luyện lại toàn bộ năm mô hình và ghi nhận R^2 , MSE trên tập kiểm tra. Đường cong hiệu suất theo số đặc trưng cho phép xác định:

1. Mô hình và số đặc trưng cho hiệu suất tối ưu.
2. Điểm bão hòa, tại đó việc thêm đặc trưng không còn cải thiện đáng kể hiệu suất.
3. Tổ hợp đặc trưng tối thiểu đủ để dự đoán HPR với độ chính xác chấp nhận được, giúp giảm chi phí đo lường và lắp đặt cảm biến trong vận hành thực tế.

Việc khởi đầu từ top-3 (thay vì từ một đặc trưng) phản ánh thực tế rằng quá trình lên men được chi phối đồng thời bởi một nhóm nhỏ yếu tố cốt lõi, đồng thời rút ngắn vùng khảo sát có ít ý nghĩa thực tiễn.

Phương pháp này cho phép xác định tổ hợp đặc trưng tối thiểu cần thiết để đạt hiệu suất dự đoán tốt, giúp đơn giản hóa mô hình và giảm chi phí đo lường trong thực tế vận hành.

2.2.11 SHAP

SHAP là phương pháp giải thích mô hình dựa trên lý thuyết trò chơi, được đề xuất bởi Lundberg và Lee [17]. SHAP gán cho mỗi đặc trưng một giá trị đóng góp cho từng dự đoán cụ thể, bao gồm cả dấu (chiều hướng ảnh hưởng) và cường độ (mức độ ảnh hưởng).

Giá trị Shapley của đặc trưng j cho dự đoán $f(x)$:

$$\phi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [f(S \cup \{j\}) - f(S)] \quad (2.12)$$

trong đó N là tập tất cả đặc trưng, S là tập con không chứa j , và $f(S)$ là giá trị dự đoán khi chỉ sử dụng các đặc trưng trong S .

SHAP thuộc lớp các phương pháp gán đóng góp đặc trưng cộng tính, trong đó giải thích cho một dự đoán được biểu diễn dưới dạng tổng đóng góp của từng đặc trưng [17]:

$$g(z') = \phi_0 + \sum_{j=1}^M \phi_j z'_j \quad (2.13)$$

với ϕ_0 là giá trị cơ sở (giá trị dự đoán trung bình khi không có đặc trưng nào), ϕ_j là giá trị Shapley của đặc trưng j , và $z'_j \in \{0, 1\}$ biểu thị sự hiện diện của đặc trưng. Điểm mạnh của giá trị Shapley là thỏa mãn đồng thời ba tính chất mong muốn của một phương pháp giải thích: (1) tính chính xác cục bộ – tổng các đóng góp bằng đúng giá trị dự đoán; (2) tính khuyết – đặc trưng không xuất hiện có đóng góp bằng 0; và (3) tính nhất quán – nếu

một mô hình thay đổi sao cho đóng góp biên của một đặc trưng tăng, thì giá trị Shapley của đặc trưng đó không giảm [17]. Đây là cơ sở lý thuyết khiến SHAP trở thành một trong những phương pháp giải thích mô hình được sử dụng rộng rãi nhất hiện nay.

SHAP là phương pháp sau huấn luyện, khác với GRA là phương pháp trước huấn luyện. GRA đánh giá mức độ tương quan giữa từng đặc trưng và biến mục tiêu một cách độc lập với mô hình, trong khi SHAP đo đóng góp thực tế của đặc trưng bên trong một mô hình cụ thể đã được huấn luyện, do đó có khả năng phản ánh các tương tác và quan hệ phi tuyến mà mô hình đã học. Sự kết hợp hai phương pháp này cho phép đánh giá tính nhất quán giữa mức độ ảnh hưởng lý thuyết theo GRA và đóng góp thực tế trong mô hình theo SHAP, đồng thời phát hiện những đặc trưng có vai trò phi tuyến mà phân tích tương quan đơn thuần có thể bỏ sót.

2.2.12 Các chỉ số đánh giá mô hình

Ba chỉ số được sử dụng để đánh giá hiệu suất mô hình hồi quy:

Sai số bình phương trung bình:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.14)$$

MSE đo trung bình bình phương sai số giữa giá trị thực và giá trị dự đoán. Giá trị MSE càng nhỏ, mô hình càng chính xác.

Hệ số xác định (R^2):

$$R^2 = 1 - \frac{SS_e}{SS_t} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (2.15)$$

R^2 đo tỷ lệ phương sai của biến mục tiêu được giải thích bởi mô hình. Quy ước đánh giá: $R^2 > 0.75$ là tốt, $0.5 \leq R^2 \leq 0.75$ là chấp nhận được, $R^2 < 0.5$ cho thấy mô hình có vấn đề.

Sai số tuyệt đối trung bình:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.16)$$

MAE đo trung bình giá trị tuyệt đối sai số, ít nhạy với giá trị ngoại lai hơn MSE.

Trong ba chỉ số trên, R^2 thường được dùng làm tiêu chí chính để so sánh tổng thể vì nó chuẩn hóa theo phương sai của dữ liệu và không phụ thuộc đơn vị, trong khi MSE và MAE bổ sung thông tin về độ lớn tuyệt đối của sai số. MSE phạt nặng các sai số lớn (do bình phương) nên nhạy với giá trị ngoại lai, còn MAE phản ánh sai số trung bình một cách cân bằng hơn. Việc sử dụng đồng thời cả ba chỉ số giúp đánh giá mô hình toàn diện hơn so với chỉ dựa vào một chỉ số duy nhất.

2.2.13 Quá khớp và chiến lược chia dữ liệu

Một thách thức cốt lõi trong học máy là hiện tượng quá khớp, khi mô hình học quá chi tiết các đặc điểm và nhiễu của tập huấn luyện, dẫn đến khả năng tổng quát hóa kém trên dữ liệu mới. Hiện tượng này đặc biệt dễ xảy ra với các mô hình có độ phức tạp cao (như DT sâu) khi số đặc trưng lớn so với số mẫu.

Để hạn chế quá khớp và đánh giá khách quan khả năng tổng quát hóa, tập dữ liệu được chia thành tập huấn luyện và tập kiểm tra, trong đó mô hình chỉ được huấn luyện trên tập huấn luyện và được đánh giá trên tập kiểm tra độc lập. Trong nghiên cứu này, tỷ lệ chia 80% huấn luyện và 20% kiểm tra được áp dụng theo thông lệ phổ biến nhằm cân bằng giữa lượng dữ liệu huấn luyện đủ lớn và tập kiểm tra đủ tin cậy. Các phương pháp ensemble như RF và XGBoost vốn có cơ chế giảm phương sai và chính quy hóa nội tại, nên thường ít bị quá khớp hơn so với mô hình cây đơn lẻ.


CHƯƠNG 3

PHƯƠNG PHÁP NGHIÊN CỨU

Chương này trình bày phương pháp nghiên cứu một cách hệ thống, đi từ mô tả hệ thống sản xuất hydrogen sinh học ở mức vật lý, xác định đầu vào – đầu ra và các yếu tố đo được cùng cảm biến tương ứng, đến cách ước lượng năng suất khi chưa có học máy, vị trí của học máy trong quy trình, cơ chế thu thập dữ liệu và hiển thị, và cuối cùng là quy trình học máy chi tiết bao gồm lựa chọn đặc trưng đa phương pháp.

3.1 Tổng quan hệ thống sản xuất hydrogen sinh học

Nghiên cứu sử dụng dữ liệu từ một hệ thống reactor lên men kỵ khí quy mô thử nghiệm tại Đại học Phùng Giáp, Đà Trung, Đà Loan. Sơ đồ quy trình được trình bày trong Hình 3.1.



Hình 3.1: Sơ đồ quy trình hệ thống sản xuất hydrogen sinh học bằng lên men kỵ khí ở quy mô thử nghiệm.

Dòng vật chất trong hệ thống diễn ra như sau. Dung dịch cơ chất sucrose từ bình chứa cơ chất được bơm nhu động đưa vào bình phản ứng. Bên trong bình phản ứng, quần thể vi sinh vật kỵ khí được duy trì ở nhiệt độ ổn định nhờ bộ ổn nhiệt thực hiện quá trình lên men tối, phân giải sucrose thành khí hydro (H_2), khí CO_2 và các acid hữu cơ acetate, butyrate, propionate cùng ethanol. Hỗn hợp khí–lỏng đi qua bộ tách khí–lỏng; phần khí giàu H_2 được dẫn tới bình thu khí, phần lỏng chảy vào bình chứa nước thải đầu ra. Một phần dòng lỏng được tuần hoàn trở lại bình phản ứng nhằm ổn định quần thể vi sinh và điều kiện vận hành. Hệ thống bố trí các cổng lấy mẫu khí và lỏng phục vụ phân tích định kỳ, cùng bơm khí hỗ trợ vận hành.

Giống vi sinh vật ban đầu được lấy từ bể lắng cuối của nhà máy xử lý nước thải (WWTP) và được thuần hóa với cơ chất sucrose trước khi vận hành chính thức. Hệ thống được vận hành liên tục để thu thập dữ liệu ổn định theo thời gian.

3.2 Đầu vào, đầu ra và bài toán dự đoán

Xét trên phương diện vận hành, hệ thống có thể được mô tả qua ba nhóm đại lượng:

- **Đầu vào điều khiển (cơ chất và điều kiện vận hành):** nồng độ cơ chất nạp tính theo COD (g COD/L), lưu lượng nạp (chi phối thời gian lưu thủy lực HRT), tỷ lệ tuần hoàn và nhiệt độ duy trì bởi thermostat.
- **Trạng thái sinh hóa trung gian (đo được):** pH, thế oxy hóa khử tại các độ sâu, nồng độ sinh khối, các acid béo bay hơi gồm acetate, propionate, butyrate và tổng VFA, ethanol, COD đầu ra và mức độ phân huỷ sucrose. Đây chính là các đặc trưng đầu vào của mô hình dự đoán.
- **Đầu ra mục tiêu:** tốc độ tạo hydro, đơn vị $L\ H_2/h/L$ (lít hydro trên giờ trên lít thể tích reactor). HPR là chỉ số năng suất tức thời quan trọng nhất, phản ánh trực tiếp hiệu quả của reactor.

Điều kiện thí nghiệm tiêu biểu: thể tích reactor 4 L; cơ chất sucrose ở nồng độ khoảng 20 g COD/L (biến thiên 20–40 g COD/L); HRT khoảng 12 h (biến thiên 2–12 h); tỷ lệ tuần hoàn khoảng 0.2 (biến thiên 0–1.0).

Bài toán nghiên cứu là: *từ các yếu tố sinh hóa đo được, dự đoán HPR* mà không phải lúc nào cũng trông cậy vào phép đo lưu lượng khí trực tiếp.

3.3 Các yếu tố đo được, cảm biến và đơn vị

Mỗi yếu tố trong hệ thống được đo bằng một phương pháp/cảm biến riêng với đơn vị xác định, như tổng hợp trong Bảng 3.1. Các yếu tố được chia thành hai nhóm: nhóm đo trực tuyến bằng điện cực/cảm biến cắm trực tiếp trong reactor, và nhóm phân tích ngoại tuyến phải lấy mẫu qua cổng lấy mẫu rồi phân tích trong phòng thí nghiệm.

Bảng 3.1: Các yếu tố đo được, phương pháp/cảm biến đo và đơn vị.

Yếu tố	Đơn vị	Chế độ	Phương pháp / cảm biến đo
pH	– (0–14)	Online	Điện cực pH đặt trong reactor
ORP_Mid, ORP_Low	mV	Online	Điện cực thể oxy hóa khử ở hai độ sâu
Nhiệt độ	°C	Online	Cảm biến nhiệt kết hợp bộ ổn nhiệt
Lưu lượng khí	mL/h	Online	Thiết bị đo lưu lượng khí
VSS	g/L	Offline	Sấy 105 °C và nung 550 °C (APHA Standard Methods)
COD-O (COD đầu ra)	mg/L	Offline	Phương pháp COD (closed reflux / so màu quang phổ)
Sucrose_Degradation	%	Offline	Tính từ đường chuẩn tổng đường vào/ra
Ethanol	mg/L	Offline	Sắc ký khí
Acetate, Propionate, Butyrate	mg/L	Offline	Sắc ký khí / HPLC
VFA (tổng)	mg/L	Offline	Tổng hợp từ các thành phần VFA
HPR (mục tiêu)	L/h/L	Online	Lưu lượng biogas $\times$ %H ₂ chia thể tích reactor


Việc phân biệt online/offline có ý nghĩa thực tiễn quan trọng: các yếu tố online luôn sẵn có theo thời gian thực, trong khi các yếu tố offline chỉ có sau mỗi chu kỳ lấy mẫu và phân tích. Đây là một động lực để tìm tổ hợp đặc trưng tối thiểu (Mục 3.8) nhằm giảm phụ thuộc vào các phép phân tích offline tốn kém.

3.4 Thiết bị thu thập dữ liệu cảm biến (DAQ)

Để số hóa nhóm tín hiệu đo trực tuyến và đưa vào quy trình dự đoán, hệ thống sử dụng một thiết bị thu thập dữ liệu (Data Acquisition – DAQ) đặt tại bể phản ứng. Thiết bị có nhiệm vụ đọc các cảm biến, gắn dấu thời gian cho mỗi mẫu đo, ghi đệm cục bộ và truyền dữ liệu về máy chủ. Sơ đồ khối của thiết bị và luồng dữ liệu được trình bày trong Hình 3.2.

Thiết bị dựa trên vi điều khiển **ESP32** tích hợp sẵn WiFi, đọc đồng thời sáu cảm biến trực tuyến: bốn cảm biến cho tín hiệu analog (pH, ORP tầng giữa, ORP tầng đáy và nồng độ H₂) cùng hai cảm biến cho tín hiệu số (nhiệt độ và lưu lượng khí). Các tín hiệu được số hóa và xử lý ngay trên thiết bị trước khi truyền đi.

Mỗi mẫu đo được gắn dấu thời gian để bảo đảm trục thời gian chính xác cho phân tích chuỗi dữ liệu. Dữ liệu vừa được ghi đệm cục bộ phòng khi mất kết nối, vừa truyền trực tuyến qua WiFi về máy chủ. Tại máy chủ, dịch vụ `predict-service` (Flask) và ứng dụng WebApp (Laravel) tiếp nhận, lưu vào cơ sở dữ liệu MySQL, chạy mô hình học máy dự đoán HPR và hiển thị kết quả trên dashboard giám sát.



Hình 3.2: Sơ đồ khối tổng quát của hệ thống và luồng dữ liệu.

3.5 Cách ước lượng HPR khi chưa dùng học máy

Trước khi áp dụng học máy, năng suất hydro thường được xác định hoặc ước lượng theo ba căn cứ:

1. **Đo trực tiếp và cân bằng vật chất khí:** HPR được tính bằng lưu lượng biogas nhân với tỷ lệ phần trăm H_2 (đo bằng GC hoặc cảm biến khí), chia cho thể tích reactor. Đây là phép *đo* chứ không phải *dự đoán*: chỉ biết được giá trị *sau khi* reactor đã vận hành và đòi hỏi thiết bị đo khí chính xác, hoạt động ổn định.
2. **Mô hình động học kinh nghiệm:** các mô hình như Modified Gompertz hoặc logistic được dùng để mô tả đường cong tích lũy hydro theo thời gian, với các tham số như tiềm năng sinh hydro tối đa, tốc độ sinh khí cực đại và pha trễ. Các mô hình này phù hợp với thí nghiệm theo mẻ, phải hiệu chỉnh tham số riêng cho từng điều kiện và *khó tổng quát hóa* cho hệ vận hành liên tục với nhiều yếu tố biến thiên.
3. **Tương quan thực nghiệm theo điều kiện vận hành:** dựa trên kinh nghiệm để chọn HRT, OLR, pH “tối ưu” rồi suy đoán năng suất. Cách này mang tính định tính, phụ thuộc nhiều vào người vận hành và không định lượng được tương tác giữa các yếu tố.

Điểm chung của các căn cứ trên là hoặc *chỉ biết sau khi đã vận hành* (đo trực tiếp), hoặc *đơn biến/đơn điều kiện* và khó nắm bắt mối quan hệ phi tuyến đồng thời giữa nhiều yếu tố sinh hóa. Trong khi đó, việc chạy thí nghiệm để dò điều kiện tối ưu rất tốn kém và mất thời gian. Đây chính là khoảng trống mà mô hình dự đoán dựa trên dữ liệu hướng tới giải quyết.

3.6 Vị trí của học máy trong quy trình

Học máy không thay thế reactor hay hệ thống cảm biến, mà là một *lớp phân tích phần mềm* đặt sau khâu thu thập dữ liệu. Luồng xử lý tổng thể:

Reactor + cảm biến/cổng lấy mẫu → Thu thập & lưu dữ liệu → Tiền xử lý + chuẩn hóa
→ **Mô hình ML dự đoán HPR** → Dashboard hiển thị + hỗ trợ vận hành

Mô hình ML nhận các yếu tố sinh hóa đo được (hoặc một tập con tối ưu của chúng) làm đầu vào và xuất ra giá trị HPR dự đoán. Nhờ đó, người vận hành có thể ước lượng năng suất *trước hoặc song song* với phép đo khí thực tế, phục vụ giám sát và ra quyết định điều chỉnh điều kiện vận hành (HRT, OLR, tỷ lệ tuần hoàn). Trong hệ thống phần mềm đã xây dựng, dịch vụ dự đoán (predict-service, Flask) chịu trách nhiệm chạy mô hình, còn ứng dụng web (WebApp, Laravel) cung cấp giao diện dashboard, lịch sử dự đoán và quản lý mô hình.

3.7 Tần suất thu thập dữ liệu và hiển thị dashboard

Các yếu tố online (pH, ORP, nhiệt độ, lưu lượng khí) được đọc liên tục hoặc theo chu kỳ ngắn bằng cảm biến cắm trực tiếp. Các yếu tố offline (VSS, COD, VFA, ethanol, mức phân huỷ sucrose) được lấy mẫu và phân tích theo lịch. Trong bộ dữ liệu nghiên cứu, các bản ghi quan sát cách nhau trung vị khoảng 8 giờ (trung bình 8,3 giờ, dao động 1,3–14,5 giờ), tương ứng nhịp lấy mẫu vài lần mỗi ngày trong suốt quá trình vận hành. Như vậy hệ thống không đọc dữ liệu phân tích sinh hóa một cách liên tục từng giây, mà theo *chu kỳ lấy mẫu* phù hợp với động học chậm của quá trình sinh học.

Về hiển thị, ứng dụng web cung cấp dashboard cho phép người vận hành theo dõi giá trị HPR dự đoán, so sánh với giá trị đo, xem lịch sử dự đoán và xu hướng theo thời gian, cũng như quản lý và so sánh các mô hình ML. Nhờ đó kết quả dự đoán được đưa trực tiếp vào quy trình hỗ trợ quyết định vận hành.

3.8 Quy trình dữ liệu và học máy

Quy trình xử lý dữ liệu và học máy được thực hiện theo các bước sau:

1. **Thu thập dữ liệu:** Trích xuất 11 đặc trưng sinh hóa và HPR từ dữ liệu vận hành reactor, thu được 216 bản ghi thô.
2. **Lọc bản ghi quan sát:** Chỉ giữ các bản ghi có dấu thời gian hợp lệ để loại bỏ các dòng thông kê/chân bảng, tránh việc nội suy nhầm vào tập huấn luyện.
3. **Xử lý giá trị thiếu:** Áp dụng nội suy tuyến tính cho các giá trị thiếu, sau đó loại bỏ các dòng còn khuyết. Tập dữ liệu sạch gồm **197 mẫu**.

4. **Chuẩn hóa dữ liệu:** Sử dụng MinMaxScaler để đưa đặc trưng về khoảng $[0, 1]$:

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \quad (3.1)$$

Bộ chuẩn hóa được khớp chỉ trên tập huấn luyện để tránh rò rỉ dữ liệu.

5. **Xếp hạng đặc trưng đa phương pháp:** Tính grey relational grade và IG cho 11 đặc trưng, sau đó hợp nhất thành thứ hạng tổng hợp (Mục 3.9).
6. **Chia dữ liệu:** Phân chia 80% huấn luyện và 20% kiểm tra (`random_state = 42`).
7. **Huấn luyện mô hình:** Huấn luyện và so sánh 5 thuật toán: SVR (kernel RBF, $C = 1$), DT, RF (100 cây), KNN ($k = 5$), XGBoost (100 cây, tốc độ học 0.1).
8. **Thêm đặc trưng tuần tự từ top-3:** Bắt đầu với 3 đặc trưng mạnh nhất rồi nâng dần lên đến 11, ghi nhận R^2 và MSE để xác định mô hình và tổ hợp đặc trưng tối ưu.
9. **Phân tích SHAP:** Giải thích mô hình tối ưu bằng SHAP và đối chiếu với xếp hạng GRA, IG.

3.9 Lựa chọn đặc trưng đa phương pháp

Như đã trình bày trong cơ sở lý thuyết, GRA và thêm đặc trưng tuần tự chỉ là một số trong nhiều cách lựa chọn đặc trưng. Nghiên cứu này áp dụng quy trình ba bước kết hợp hai phương pháp xếp hạng độc lập:

1. **Xếp hạng song song bằng GRA và IG.** GRA đo mức độ tương đồng hình dạng giữa chuỗi đặc trưng và chuỗi HPR sau chuẩn hóa; IG đo lượng thông tin đặc trưng đóng góp cho việc giảm bất định của HPR. Hai phương pháp phản ánh hai khía cạnh khác nhau của tầm quan trọng.
2. **Hợp nhất thứ hạng.** Với mỗi đặc trưng, lấy trung bình thứ hạng từ hai phương pháp để được thứ hạng tổng hợp; chọn ra ba đặc trưng đứng đầu (top-3).
3. **Thêm đặc trưng tuần tự bắt đầu từ top-3.** Lần lượt mở rộng tập đặc trưng từ 3 lên 11 theo thứ hạng tổng hợp; sau mỗi bước, huấn luyện lại cả 5 mô hình và đánh giá để tìm điểm tối ưu và điểm bão hòa.

Mô hình đạt hiệu suất cao nhất trên tổ hợp đặc trưng tương ứng được chọn làm *mô hình tối ưu* và được phân tích sâu bằng SHAP, qua đó so sánh tính nhất quán giữa ba phương pháp đánh giá (GRA, IG trước huấn luyện; SHAP sau huấn luyện).

3.10 Công cụ phần mềm

Nghiên cứu sử dụng các công cụ phần mềm sau:

- **Ngôn ngữ lập trình:** Python 3.11+
- **Thư viện ML:** scikit-learn [21] (MinMaxScaler, RF, DT, KNN, SVR, `mutual_info_regression`), XGBoost [4]
- **Giải thích mô hình:** SHAP [17]
- **Xử lý dữ liệu:** pandas, numpy
- **Trực quan hóa:** matplotlib, seaborn

CHƯƠNG 4

KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN

Chương này trình bày chi tiết kết quả nghiên cứu bao gồm: mô tả và tiền xử lý dữ liệu, kết quả xếp hạng đặc trưng bằng GRA, phân tích đơn biến, so sánh hiệu suất các mô hình ML, kết quả thêm đặc trưng tuần tự, và phân tích SHAP; đồng thời thảo luận ý nghĩa sinh học, đánh giá hiệu quả lựa chọn đặc trưng, đối chiếu với các nghiên cứu liên quan, nhận diện hạn chế và đề xuất hướng phát triển.

4.1 Mô tả dữ liệu

Dữ liệu được thu thập từ hệ thống reactor quy mô thử nghiệm vận hành liên tục tại Đại học Phùng Giáp. Sau khi tiền xử lý (loại bỏ giá trị thiếu bằng nội suy tuyến tính), tập dữ liệu gồm 197 mẫu quan sát với 11 đặc trưng đầu vào và 1 biến mục tiêu HPR.


Bảng 4.1 trình bày thống kê mô tả của tập dữ liệu sau khi chuẩn hóa MinMaxScaler về khoảng $[0, 1]$.

Bảng 4.1: Thống kê mô tả tập dữ liệu sau chuẩn hóa ($n = 197$)

Đặc trưng	Trung bình	Độ lệch chuẩn	Nhỏ nhất	25%	50%	Lớn nhất
pH	0.235	0.127	0.0	0.157	0.221	1.0
VSS	0.358	0.154	0.0	0.252	0.301	1.0
Ethanol	0.474	0.253	0.0	0.281	0.394	1.0
Acetate	0.447	0.226	0.0	0.266	0.390	1.0
Propionate	0.367	0.216	0.0	0.213	0.280	1.0
Butyrate	0.429	0.247	0.0	0.263	0.344	1.0
Sucrose Degradation	0.804	0.146	0.0	0.775	0.809	1.0
ORP _{Mid}	0.346	0.267	0.0	0.140	0.338	1.0
ORP _{Low}	0.525	0.175	0.0	0.429	0.490	1.0
VFA	0.429	0.235	0.0	0.253	0.336	1.0
COD-O	0.508	0.197	0.0	0.367	0.506	1.0
HPR (mục tiêu)	0.365	0.277	0.0	0.143	0.228	1.0

Biến mục tiêu HPR có giá trị trung bình 0.365 với độ lệch chuẩn 0.277, cho thấy phân bố lệch phải – phần lớn các mẫu có HPR thấp đến trung bình, với một số ít mẫu đạt HPR cao. Đặc trưng Sucrose Degradation có giá trị trung bình cao nhất (0.804), phản ánh hiệu suất phân hủy cơ chất ổn định trong hệ thống.


Để khảo sát hình dạng phân bố của từng đặc trưng, Hình 4.1 trình bày biểu đồ phân bố của các đặc trưng và biến mục tiêu sau khi chuẩn hóa.



Hình 4.1: Phân bố của các đặc trưng và biến mục tiêu sau chuẩn hóa

Nhiều đặc trưng thể hiện phân bố lệch phải tương tự biến mục tiêu HPR, đặc biệt là các đặc trưng liên quan đến acid béo bay hơi. Điều này phản ánh đặc tính của dữ liệu vận hành thực tế, trong đó phần lớn thời gian hệ thống hoạt động ở vùng giá trị thấp đến trung bình và chỉ thỉnh thoảng đạt các giá trị cao. Đặc điểm phân bố lệch này củng cố lựa chọn sử dụng GRA – vốn không yêu cầu giả định phân phối chuẩn – để xếp hạng đặc trưng.

Hình 4.2 sử dụng biểu đồ hộp để thể hiện khoảng phân tán và các giá trị ngoại lai của từng đặc trưng.




Hình 4.2: Biểu đồ hộp thể hiện phân tán và giá trị ngoại lai của các đặc trưng

Biểu đồ hộp cho thấy một số đặc trưng tồn tại các điểm ngoại lai ở vùng giá trị cao, phù hợp với bản chất phân bố lệch phải đã quan sát. Sự hiện diện của giá trị ngoại lai là một yếu tố cần lưu ý khi lựa chọn thuật toán: các mô hình ensemble như RF và XGBoost vốn ít nhạy với giá trị ngoại lai nhờ cơ chế tổng hợp, trong khi các mô hình dựa trên khoảng cách như KNN được hưởng lợi từ bước chuẩn hóa MinMaxScaler đã áp dụng.

4.2 Phân tích tương quan giữa các đặc trưng

Trước khi xếp hạng đặc trưng bằng GRA, ma trận hệ số tương quan Pearson giữa các đặc trưng và biến mục tiêu được tính toán nhằm nhận diện các mối quan hệ tuyến tính và hiện tượng đa cộng tuyến. Hình 4.3 trình bày ma trận tương quan dưới dạng bản đồ nhiệt.



Hình 4.3: Bản đồ nhiệt ma trận hệ số tương quan Pearson giữa 11 đặc trưng và HPR

Xét tương quan với biến mục tiêu HPR, các đặc trưng có hệ số tương quan dương cao nhất là VFA (0.798), Butyrate (0.783), Acetate (0.764), VSS (0.706) và Ethanol (0.611). Đây đều là các sản phẩm trao đổi chất hoặc chỉ thị sinh khối phản ánh mức độ hoạt động của quá trình lên men. Ngược lại, ORP_{Mid} có tương quan âm rõ rệt với HPR (-0.545), phù hợp với cơ chế ORP tăng khi quá trình sinh acid tiến triển và HPR giảm. Các đặc trưng pH (-0.127), Sucrose Degradation (0.074) và ORP_{Low} (-0.135) có tương quan tuyến tính yếu với HPR.

Đáng chú ý, một số cặp đặc trưng thể hiện tương quan rất cao với nhau, điển hình là VFA với Butyrate (0.960), VFA với Acetate (0.943), và Acetate với Butyrate (0.865). Điều này hợp lý về mặt sinh hóa vì VFA là tổng hợp của các acid béo bay hơi bao gồm acetate, propionate và butyrate. Hiện tượng đa cộng tuyến này gợi ý rằng một số đặc trưng mang thông tin chồng lấn, và do đó việc lựa chọn đặc trưng có hệ thống (trình bày ở các mục sau) là cần thiết để tránh dư thừa và nhiễu cho mô hình.

4.3 Tiền xử lý dữ liệu

Quy trình tiền xử lý dữ liệu gồm hai bước chính:

Xử lý giá trị thiếu: Các giá trị thiếu trong dữ liệu gốc được xử lý bằng phương pháp nội suy tuyến tính, phù hợp với đặc tính tuần tự của dữ liệu vận hành reactor.

Chuẩn hóa dữ liệu: Tất cả đặc trưng và biến mục tiêu được chuẩn hóa về khoảng $[0, 1]$ bằng MinMaxScaler:

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \quad (4.1)$$

Việc chuẩn hóa đảm bảo các đặc trưng có thang đo đồng nhất, đặc biệt quan trọng cho thuật toán KNN (nhạy cảm với khoảng cách Euclidean) và SVR.


Dữ liệu sau tiền xử lý được chia thành tập huấn luyện (80%, 157 mẫu) và tập kiểm tra (20%, 40 mẫu).

4.4 Kết quả GRA

Bảng 4.2 trình bày kết quả xếp hạng 11 đặc trưng theo grey relational grade với biến mục tiêu HPR.

Bảng 4.2: Xếp hạng đặc trưng theo Grey Relational Grade

Hạng	Đặc trưng	Grey Relational Grade
1	VFA	0.7931
2	Butyrate	0.7902
3	Acetate	0.7772
4	VSS	0.7768
5	Propionate	0.7596
6	Ethanol	0.7329
7	COD-O	0.7183
8	pH	0.7102
9	ORP _{Low}	0.6396
10	ORP _{Mid}	0.6217
11	Sucrose Degradation	0.5834



Hình 4.4: Biểu đồ xếp hạng Grey Relational Grade của 11 đặc trưng


Kết quả cho thấy VFA (0.7931) có mức độ tương quan cao nhất với HPR, tiếp theo là Butyrate (0.7902) và Acetate (0.7772). Ba đặc trưng hàng đầu đều thuộc nhóm acid béo bay hơi hoặc sản phẩm trao đổi chất, phù hợp với cơ chế sinh học của lên men tối – các con đường trao đổi chất sản xuất VFA đồng thời giải phóng H_2 . Ngược lại, Sucrose Degradation (0.5834) có grade thấp nhất, cho thấy hiệu suất phân hủy cơ chất không phải yếu tố quyết định trực tiếp đến HPR.

Thứ hạng GRA trong nghiên cứu này nhất quán với phát hiện của nghiên cứu gốc về tầm quan trọng của nhóm acid béo bay hơi và butyrate đối với quá trình sản xuất hydrogen từ sucrose [8]. Đáng lưu ý, thứ hạng thu được từ GRA phản ánh khá sát thứ tự của hệ số tương quan Pearson đã trình bày ở mục trước (VFA, Butyrate, Acetate, VSS đều nằm trong nhóm dẫn đầu ở cả hai phương pháp), cho thấy tính ổn định của kết quả xếp hạng đặc trưng. Tuy nhiên, GRA không bị ràng buộc bởi giả định phân phối chuẩn hay kích thước mẫu, nên phù hợp hơn với dữ liệu sinh học có tính phi tuyến và phân bố lệch như trong nghiên cứu này. Khoảng cách grade giữa các đặc trưng tương đối nhỏ ở nhóm giữa bảng xếp hạng, hàm ý rằng ranh giới đóng góp giữa các đặc trưng này không rõ rệt và cần được kiểm chứng thêm thông qua quá trình thêm đặc trưng tuần tự.

4.5 Xếp hạng bằng IG và hợp nhất thứ hạng

Để kiểm chứng chéo kết quả của GRA, nghiên cứu tính IG giữa từng đặc trưng và HPR bằng phương pháp ước lượng dựa trên k láng giềng gần nhất [12]. Hình 4.5 so sánh trực

quan hai bảng xếp hạng GRA và IG.



Hình 4.5: So sánh xếp hạng đặc trưng: IG (trái) và Grey Relational Grade (phải)

Theo IG, ba đặc trưng mang nhiều thông tin nhất về HPR là VFA (0.816), Acetate (0.676) và Butyrate (0.670), tiếp theo là ORP_{Mid} (0.625) và VSS (0.568). Hai đặc trưng có IG thấp nhất là Sucrose Degradation (0.268) và pH (0.177). Kết quả này về cơ bản đồng thuận với GRA ở nhóm dẫn đầu gồm VFA, Acetate, Butyrate và nhóm cuối bảng gồm Sucrose Degradation, pH, củng cố độ tin cậy của việc xác định các đặc trưng then chốt. Khác biệt rõ nhất nằm ở ORP_{Mid}: được IG xếp hạng cao (hạng 4) nhưng GRA xếp hạng thấp (hạng 10), gợi ý ORP_{Mid} mang thông tin phi tuyến về HPR mà phép đo tương đồng hình dạng của GRA không nắm bắt đầy đủ.

Bảng 4.3 trình bày thứ hạng tổng hợp, tính bằng trung bình thứ hạng của hai phương pháp. Khi nhiều đặc trưng có cùng thứ hạng trung bình (chẳng hạn Ethanol, COD-O và ORP_{Mid} cùng đạt 7.0), ưu tiên đặc trưng có thứ hạng GRA tốt hơn.

Bảng 4.3: Thứ hạng tổng hợp từ GRA và IG

Hạng TH	Đặc trưng	Hạng GRA	Hạng IG	Hạng TB
1	VFA	1	1	1.0
2	Butyrate	2	3	2.5
3	Acetate	3	2	2.5
4	VSS	4	5	4.5
5	Propionate	5	6	5.5
6	Ethanol	6	8	7.0
7	COD-O	7	7	7.0
8	ORP _{Mid}	10	4	7.0
9	ORP _{Low}	9	9	9.0
10	pH	8	11	9.5
11	Sucrose Degradation	11	10	10.5


Thứ hạng tổng hợp xác định **top-3 đặc trưng là VFA, Butyrate và Acetate** – nhóm

acid béo bay hơi gắn trực tiếp với con đường sản xuất H_2 . Đây là điểm khởi đầu cho quá trình thêm đặc trưng tuần tự ở mục sau.

Kết quả này trả lời trực tiếp cho **Câu hỏi nghiên cứu 1**: trong số 11 đặc trưng được khảo sát, nhóm acid béo bay hơi gồm VFA, Butyrate và Acetate là các yếu tố có mức độ tương quan mạnh nhất với HPR, với thứ tự ảnh hưởng được xác định nhất quán qua cả GRA và IG.

4.6 Phân tích đơn biến

Hình 4.6 trình bày mối quan hệ giữa từng đặc trưng với HPR thông qua biểu đồ phân tán.



Hình 4.6: Phân tích đơn biến: quan hệ từng đặc trưng với HPR

Các đặc trưng VFA, Butyrate, và Acetate thể hiện xu hướng tương quan dương rõ rệt với HPR, nhất quán với kết quả GRA. Đặc trưng ORP_{Mid} và ORP_{Low} có mối quan hệ phi tuyến phức tạp hơn, giải thích vì sao chúng có grey relational grade thấp hơn mặc dù vẫn có ảnh hưởng đến HPR.


4.7 So sánh hiệu suất mô hình

Năm mô hình ML được huấn luyện trên toàn bộ 11 đặc trưng. Bảng 4.4 trình bày kết quả đánh giá trên tập kiểm tra.

Bảng 4.4: So sánh hiệu suất các mô hình ML trên tập kiểm tra (sai số quy về thang gốc, đơn vị L/h/L)

Mô hình	R^2	MSE (L/h/L) ²	RMSE (L/h/L)	MAE (L/h/L)
KNN	0.8172	6.18	2.49	1.65
RF	0.7756	7.59	2.76	1.84
XGBoost	0.7495	8.50	2.91	2.10
SVR	0.7324	9.04	3.01	2.08
DT	0.5605	14.88	3.86	2.39

Do biến mục tiêu HPR được chuẩn hóa về khoảng $[0, 1]$ bằng MinMaxScaler trong quá trình huấn luyện, các chỉ số sai số (MSE, RMSE, MAE) trong Bảng 4.4 đã được quy đổi ngược về thang gốc bằng khoảng biến thiên của HPR trên tập huấn luyện ($HPR_{\max} - HPR_{\min} = 21,98 \text{ L/h/L}$), nhờ đó phản ánh đúng độ lớn sai số theo đơn vị vật lý L/h/L thay vì trên thang chuẩn hóa không thứ nguyên. Cụ thể, $RMSE_{\text{gốc}} = RMSE_{\text{chuẩn hóa}} \times 21,98$ và $MSE_{\text{gốc}} = MSE_{\text{chuẩn hóa}} \times 21,98^2$; riêng hệ số R^2 không phụ thuộc thang đo nên giữ nguyên giá trị.



Hình 4.7: So sánh hiệu suất các mô hình: (a) Hệ số R^2 , (b) MSE, (c) Biểu đồ phân tán giá trị dự đoán so với thực tế

KNN đạt hiệu suất tốt nhất với $R^2 = 0.817$ và RMSE = 2,49 L/h/L, vượt trội so với các mô hình còn lại. RF xếp thứ hai ($R^2 = 0.776$), tiếp theo là XGBoost ($R^2 = 0.749$) và SVR ($R^2 = 0.732$). DT có hiệu suất thấp nhất ($R^2 = 0.560$), cho thấy mô hình đơn lẻ không đủ khả năng nắm bắt mối quan hệ phi tuyến phức tạp trong dữ liệu.


Theo quy ước đánh giá hệ số xác định, bốn mô hình KNN, RF, XGBoost và SVR đều đạt $R^2 > 0.75$ – mức được xem là tốt, trong khi DT chỉ nằm trong khoảng chấp nhận được ($0.5 < R^2 \leq 0.75$). Thứ tự sai số hoàn toàn nhất quán với thứ tự R^2 : KNN có sai số nhỏ nhất (RMSE = 2,49 L/h/L) còn DT có sai số lớn nhất (RMSE = 3,86 L/h/L), xác nhận tính ổn định của kết quả đánh giá khi xét đồng thời hai chỉ số. Hiệu suất thấp của DT phù hợp với nhận định chung rằng cây quyết định đơn lẻ dễ bị quá khớp khi số đặc trưng lớn và cấu trúc cây phức tạp, dẫn đến tính bất ổn cao và khả năng tổng quát hóa kém. Việc các mô hình ensemble RF và XGBoost cải thiện đáng kể so với DT khẳng định vai trò của cơ chế tổng hợp nhiều cây trong việc giảm phương sai và hạn chế quá khớp.

Một điểm đáng chú ý là KNN – một mô hình đơn giản dựa trên khoảng cách – lại vượt qua cả các mô hình ensemble phức tạp. Kết quả này cần được diễn giải trong bối cảnh đặc thù của tập dữ liệu (kích thước mẫu vừa phải, đã được chuẩn hóa MinMaxScaler) và sẽ được phân tích sâu hơn ở các mục thảo luận sau của chương này. Cần lưu ý rằng thứ hạng mô hình trong nghiên cứu này có thể khác với một số nghiên cứu trước trên các tập dữ liệu khác, do hiệu suất tương đối giữa các thuật toán phụ thuộc mạnh vào đặc tính dữ liệu và điều kiện thí nghiệm cụ thể.

Như vậy, kết quả này trả lời cho **Câu hỏi nghiên cứu 2**: KNN là thuật toán cho hiệu suất dự đoán HPR tốt nhất ($R^2 = 0,817$) trên tập dữ liệu quy mô thử nghiệm. Sự vượt trội của một mô hình đơn giản dựa trên khoảng cách so với các mô hình ensemble phức tạp phản ánh bản chất của dữ liệu: kích thước mẫu vừa phải, đã được chuẩn hóa MinMaxScaler và mang tính liên tục cục bộ cao – những điều kiện thuận lợi cho KNN.

4.8 Thêm đặc trưng tuần tự từ top-3

Xuất phát từ top-3 đặc trưng theo thứ hạng tổng hợp là VFA, Butyrate và Acetate, nghiên cứu lần lượt thêm từng đặc trưng theo thứ hạng tổng hợp và đánh giá lại cả 5 mô hình. Hình 4.8 và Bảng 4.5 trình bày diễn biến R^2 và MSE theo số đặc trưng.



Hình 4.8: Kết quả thêm đặc trưng tuần tự từ top-3: R^2 (trái) và MSE (phải) theo số đặc trưng

Bảng 4.5: R^2 trên tập kiểm tra theo số đặc trưng (bắt đầu từ top-3 tổng hợp)

n	Đặc trưng thêm vào	SVR	DT	RF	KNN	XGBoost
3	VFA, Butyrate, Acetate	0.734	0.313	0.775	0.739	0.609
4	+VSS	0.779	0.632	0.766	0.707	0.768
5	+Propionate	0.757	0.580	0.721	0.718	0.661
6	+Ethanol	0.706	0.593	0.746	0.746	0.679
7	+COD-O	0.724	0.582	0.744	0.762	0.664
8	+ORP _{Mid}	0.756	0.603	0.744	0.787	0.693
9	+ORP _{Low}	0.741	0.678	0.781	0.815	0.736
10	+pH	0.746	0.628	0.783	0.814	0.730
11	+Sucrose Degradation	0.732	0.632	0.784	0.818	0.751

Kết quả cho thấy một bức tranh phụ thuộc rõ rệt vào thuật toán. Tại tổ hợp tối thiểu chỉ gồm top-3 đặc trưng, **RF** đã đạt $R^2 = 0.775$ – cao nhất trong các mô hình ở mức này – chứng tỏ ba đặc trưng acid béo bay hơi mang phần lớn thông tin dự đoán và các mô hình ensemble khai thác hiệu quả ngay cả khi không gian đặc trưng rất nhỏ. Khi tăng lên 4 đặc trưng (thêm VSS), SVR và XGBoost cải thiện đáng kể (lần lượt 0.779 và 0.768).

Khi số đặc trưng tiếp tục tăng, **KNN** vươn lên dẫn đầu và đạt hiệu suất cao nhất: $R^2 = 0.815$ tại 9 đặc trưng và đạt cực đại $R^2 = 0.818$ (RMSE $\approx 2,49$ L/h/L) khi dùng đủ 11 đặc trưng (chênh lệch không đáng kể so với giá trị $R^2 = 0.817$ ở Bảng 4.4, do thí nghiệm thêm đặc trưng tuần tự được thực hiện như một lần chạy độc lập; cả hai đều ứng với RMSE $\approx 2,49$ L/h/L). Đáng chú ý, KNN gần như bão hòa từ 9 đặc trưng trở đi (0.815 $\rightarrow$ 0.818), nghĩa là hai đặc trưng cuối (pH và Sucrose Degradation) đóng góp không đáng kể. Như vậy, **mô hình tối ưu là KNN**, và nếu cần đánh đổi giữa độ chính xác và chi phí đo lường, tổ hợp 9 đặc trưng đầu tiên đã đủ đạt gần như toàn bộ hiệu suất tối đa.


Ba xu hướng đáng chú ý: Thứ nhất, các mô hình ensemble RF và XGBoost ổn định và đạt hiệu suất tốt ngay từ tổ hợp đặc trưng nhỏ, trong khi KNN cần nhiều đặc trưng hơn để phát huy nhưng cuối cùng vượt trội. Thứ hai, việc thêm các đặc trưng có thứ hạng thấp

không phải lúc nào cũng cải thiện hiệu suất; ở một số mô hình như SVR và XGBoost, hiệu suất còn dao động giảm, phản ánh thông tin dư thừa do đa cộng tuyến và nhiễu. Thứ ba, sự khác biệt về phản ứng với số đặc trưng giữa các thuật toán có ý nghĩa thực tiễn: trong vận hành, có thể ưu tiên đo một tập nhỏ thông số quan trọng nhất mà vẫn duy trì độ chính xác chấp nhận được.

Những kết quả trên trả lời cho **Câu hỏi nghiên cứu 3**: lựa chọn đặc trưng theo thứ hạng tổng hợp giúp *duy trì* gần như toàn bộ hiệu suất với số đặc trưng ít hơn – KNN bão hòa từ 9 đặc trưng ($R^2 = 0,815$ so với 0,818 khi dùng đủ 11 đặc trưng), trong khi RF chỉ với 3 đặc trưng acid béo bay hơi đã đạt $R^2 = 0,775$. Tổ hợp đặc trưng tối thiểu cần thiết do đó nằm trong khoảng 3–4 đặc trưng hàng đầu (VFA, Butyrate, Acetate và VSS) nếu chấp nhận đánh đổi một phần nhỏ độ chính xác để giảm chi phí đo lường.

4.9 Phân tích SHAP

Để giải thích mô hình tối ưu KNN, nghiên cứu áp dụng SHAP với bộ giải thích không phụ thuộc mô hình (KernelExplainer), do KNN không thuộc nhóm mô hình cây. Hình 4.9 trình bày đóng góp trung bình tuyệt đối của từng đặc trưng.



Hình 4.9: Đóng góp đặc trưng theo SHAP (trung bình |SHAP|) cho mô hình tối ưu KNN

Bảng 4.6: So sánh xếp hạng GRA, IG và SHAP (top-5)

Hạng	GRA	Hạng	IG	Hạng	SHAP
1	VFA	1	VFA	1	Butyrate
2	Butyrate	2	Acetate	2	VFA
3	Acetate	3	Butyrate	3	Acetate
4	VSS	4	ORP _{Mid}	4	VSS
5	Propionate	5	VSS	5	COD-O

Kết quả SHAP cho thấy bốn đặc trưng đóng góp lớn nhất vào mô hình KNN là Butyrate (trung bình $|\text{SHAP}| = 0.0457$), VFA (0.0368), Acetate (0.0345) và VSS (0.0320). Đây cũng chính là nhóm bốn đặc trưng dẫn đầu theo cả GRA và IG, cho thấy **sự nhất quán mạnh mẽ giữa ba phương pháp đánh giá độc lập** – hai phương pháp trước huấn luyện là GRA, IG và một phương pháp sau huấn luyện là SHAP. Ở chiều ngược lại, pH và Sucrose Degradation là hai đặc trưng có đóng góp SHAP thấp nhất (lần lượt 0.0054 và 0.0055), trùng khớp với việc chúng cũng xếp cuối ở cả GRA và IG.

Sự đồng thuận xuyên suốt ba phương pháp về vai trò của nhóm acid béo bay hơi VFA, Butyrate, Acetate và của sinh khối củng cố vững chắc kết luận về các yếu tố then chốt quyết định HPR. Đồng thời, mỗi phương pháp bổ sung một góc nhìn: GRA và IG đánh giá tương quan/thông tin độc lập với mô hình, còn SHAP làm rõ cách mô hình KNN thực sự khai thác từng đặc trưng, bao gồm cả những đóng góp qua tương tác phi tuyến. Đây chính là giá trị cốt lõi của quy trình lựa chọn đặc trưng đa phương pháp được đề xuất trong khóa luận.

Kết quả này trả lời cho **Câu hỏi nghiên cứu 4**: xếp hạng SHAP (sau huấn luyện) nhất quán mạnh với GRA và IG (trước huấn luyện) ở nhóm yếu tố then chốt (VFA, Butyrate, Acetate, VSS dẫn đầu; pH và Sucrose Degradation xếp cuối ở cả ba phương pháp). Các khác biệt cục bộ – như thứ tự Butyrate–VFA hay vị trí của ORP_{Mid} – cho thấy mô hình KNN còn khai thác thêm những đóng góp qua tương tác phi tuyến mà các phương pháp trước huấn luyện chưa nắm bắt đầy đủ.

4.10 Ý nghĩa sinh học của xếp hạng đặc trưng

Phần này thảo luận ý nghĩa của các kết quả đã trình bày ở trên, bao gồm ý nghĩa sinh học của xếp hạng đặc trưng, phân tích hiệu suất các mô hình, hiệu quả của lựa chọn đặc trưng, đối chiếu giữa GRA và SHAP, so sánh với các nghiên cứu liên quan, cùng các hạn chế và hướng phát triển.

Kết quả GRA cho thấy VFA, Butyrate, và Acetate là ba đặc trưng có ảnh hưởng lớn nhất đến HPR. Điều này hoàn toàn phù hợp với cơ chế sinh hóa của lên men tối:

- **VFA** (hạng 1, grade = 0.793): Tổng nồng độ acid béo bay hơi phản ánh trực tiếp mức độ hoạt động của quá trình acid hóa – giai đoạn chính sản sinh H₂. VFA cao

cho thấy vi sinh vật đang tích cực chuyển hóa cơ chất qua các con đường sản xuất hydrogen [30].

- **Butyrate** (hạng 2, grade = 0.790): Con đường glucose $\rightarrow$ butyrate là con đường chính sản xuất H_2 trong lên men tối, với lý thuyết cho 2 mol H_2 /mol glucose. Nồng độ butyrate cao phản ánh con đường trao đổi chất thuận lợi cho sản xuất hydrogen [6].
- **Acetate** (hạng 3, grade = 0.777): Con đường glucose $\rightarrow$ acetate cho hiệu suất lý thuyết cao nhất (4 mol H_2 /mol glucose). Sự hiện diện đồng thời của acetate và butyrate ở mức cao là dấu hiệu của hệ thống lên men hiệu quả.

VSS (hạng 4) phản ánh mật độ vi sinh vật – yếu tố nền tảng cho mọi hoạt động sinh học. Sucrose Degradation (hạng 11) có grade thấp nhất vì trong hệ thống ổn định, hiệu suất phân hủy cơ chất luôn duy trì ở mức cao (trung bình = 0.804) với biến thiên nhỏ (độ lệch chuẩn = 0.146), do đó không tạo ra sự khác biệt đáng kể giữa các mẫu.

Ngoài ba đặc trưng dẫn đầu, vai trò của các yếu tố còn lại cũng có thể được lý giải dựa trên cơ chế sinh hóa:

- **Propionate** đại diện cho con đường tiêu thụ hydrogen: khi quá trình lên men chuyển hướng sang sản xuất propionate, một phần hydrogen bị tiêu thụ thay vì được giải phóng dưới dạng khí, do đó nồng độ propionate cao thường gắn với HPR thấp hơn.
- **Ethanol** là sản phẩm dạng dung môi được tạo ra trong điều kiện kỵ khí; ở nồng độ cao, ethanol có tác động ức chế đối với một số vi khuẩn sinh hydrogen, phù hợp với xu hướng HPR giảm khi nồng độ ethanol tăng quan sát được trong phân tích đơn biến.
- **ORP** biến thiên liên tục theo các giai đoạn phản ứng (giảm khi giải phóng electron trong thủy phân, tăng khi hấp thu electron trong sinh acid), khiến mối quan hệ giữa ORP và HPR mang tính phi tuyến cao hơn so với các đặc trưng khác. Đây là lý do ORP có thể có grade GRA tương đối thấp nhưng vẫn đóng vai trò quan trọng khi được mô hình phi tuyến khai thác (xem mục so sánh GRA–SHAP).

Nhìn chung, thứ hạng đặc trưng thu được phản ánh đúng bản chất của quá trình lên men tối: các đặc trưng gắn trực tiếp với con đường sản xuất acid béo bay hơi (đặc biệt là acetate và butyrate) có ảnh hưởng mạnh nhất đến HPR, nhất quán với hiểu biết sinh hóa hiện hành [6, 7].

4.11 Phân tích hiệu suất mô hình

KNN đạt hiệu suất tốt nhất ($R^2 = 0.817$) có thể được giải thích bởi đặc tính của dữ liệu:

- **Kích thước mẫu vừa phải** (197 mẫu): KNN hoạt động hiệu quả khi tập dữ liệu không quá lớn, vì chi phí tính toán tỷ lệ với số mẫu.
- **Dữ liệu đã chuẩn hóa**: MinMaxScaler loại bỏ vấn đề khác biệt thang đo giữa các đặc trưng – nhược điểm chính của KNN.
- **Mối quan hệ cục bộ**: Dữ liệu từ reactor vận hành liên tục có tính liên tục cao – các mẫu gần nhau trong không gian đặc trưng thường có HPR tương tự.

DT có hiệu suất thấp nhất ($R^2 = 0.560$) do dễ quá khớp với 11 đặc trưng và chỉ 197 mẫu. RF khắc phục vấn đề này bằng ensemble ($R^2 = 0.776$), nhưng vẫn không vượt qua KNN. XGBoost ($R^2 = 0.749$) không đạt hiệu suất cao nhất có thể do tập dữ liệu nhỏ không đủ để phát huy ưu thế của gradient boosting.

4.12 Hiệu quả của lựa chọn đặc trưng

Quy trình lựa chọn đặc trưng đa phương pháp (GRA + IG + thêm đặc trưng tuần tự từ top-3) cho thấy hiệu quả rõ rệt:

- Chỉ với top-3 đặc trưng VFA, Butyrate và Acetate, RF đã đạt $R^2 = 0.775$ – gần bằng hiệu suất tối đa của toàn bộ nghiên cứu, khẳng định ba acid béo bay hơi mang phần lớn thông tin dự đoán.
- KNN gần như bão hòa từ 9 đặc trưng ($R^2 = 0.815$) và đạt cực đại ở 11 đặc trưng ($R^2 = 0.818$); hai đặc trưng cuối là pH và Sucrose Degradation đóng góp không đáng kể.
- Với 4 đặc trưng (thêm VSS), SVR và XGBoost đạt đỉnh cục bộ (lần lượt 0.779 và 0.768).

Kết quả này có ý nghĩa thực tiễn: trong vận hành bể phản ứng sinh học, chỉ cần đo một tập nhỏ thông số quan trọng gồm VFA, butyrate, acetate, VSS là đủ để dự đoán HPR với độ chính xác chấp nhận được, giảm đáng kể chi phí phân tích mẫu offline.

4.13 So sánh GRA, IG và SHAP

Việc đối chiếu ba phương pháp đánh giá đặc trưng – GRA và IG (trước huấn luyện), SHAP (sau huấn luyện) – cho thấy mức độ nhất quán cao ở các yếu tố then chốt và một vài khác biệt cục bộ giàu ý nghĩa:

- **Nhất quán mạnh**: Nhóm bốn đặc trưng VFA, Butyrate, Acetate và VSS nằm trong nhóm dẫn đầu ở cả ba phương pháp GRA, IG và SHAP; pH và Sucrose Degradation đều xếp cuối ở cả ba.

- **Khác biệt cục bộ:** ORP_{Mid} được IG xếp hạng cao (hạng 4) nhưng GRA xếp hạng thấp (hạng 10), cho thấy ORP_{Mid} mang thông tin phi tuyến về HPR mà phép đo tương đồng hình dạng của GRA không nắm bắt đầy đủ.

Sự kết hợp ba phương pháp cung cấp cái nhìn toàn diện: GRA và IG xác định các yếu tố quan trọng một cách độc lập với mô hình (trước huấn luyện), còn SHAP làm rõ cách mô hình thực sự khai thác từng đặc trưng (sau huấn luyện), bao gồm cả các tương tác phi tuyến.

4.14 So sánh với nghiên cứu liên quan

So với các nghiên cứu dự đoán HPR bằng ML:

- Hosseinzadeh và cộng sự [8] đạt $R^2 = 0.94$ với ANN cho dữ liệu hydrogen sinh học từ nước thải, nhưng sử dụng tập dữ liệu lớn hơn và điều kiện thí nghiệm khác biệt.
- Pandey và cộng sự [19] tổng hợp các nghiên cứu ML cho hydrogen sinh học với R^2 dao động 0.75–0.98 tùy thuộc vào loại dữ liệu và thuật toán.
- Nghiên cứu này đạt $R^2 = 0.817$ với KNN trên dữ liệu quy mô thử nghiệm thực tế, nằm trong khoảng chấp nhận được ($R^2 > 0.75$).

Điểm khác biệt của nghiên cứu này là quy trình kết hợp GRA + thêm đặc trưng tuần tự + SHAP, cung cấp không chỉ mô hình dự đoán mà còn thông tin giải thích về vai trò của từng yếu tố.

Một điểm cần thảo luận thêm là sự khác biệt về thuật toán cho hiệu suất tốt nhất giữa các nghiên cứu. Trong các nghiên cứu về năng lượng sinh học kỵ khí, các mô hình ensemble dạng cây như RF và XGBoost thường được báo cáo là cho hiệu suất hàng đầu trên những tập dữ liệu lớn và phức tạp [31, 1]. Tuy nhiên, trong nghiên cứu này, KNN lại vượt trội. Sự khác biệt này không mâu thuẫn mà phản ánh một nguyên tắc quan trọng trong học máy: không có thuật toán nào tối ưu cho mọi bài toán, và hiệu suất tương đối giữa các mô hình phụ thuộc mạnh vào đặc tính dữ liệu (kích thước mẫu, mức độ nhiễu, cấu trúc cục bộ, mức độ chuẩn hóa). Với tập dữ liệu có kích thước vừa phải, đã được chuẩn hóa tốt và mang tính liên tục cao như trong nghiên cứu này, mô hình dựa trên khoảng cách như KNN có thể khai thác hiệu quả cấu trúc cục bộ của dữ liệu. Điều này càng nhấn mạnh tầm quan trọng của việc so sánh nhiều thuật toán thay vì giả định trước một mô hình tối ưu.

4.15 Hạn chế

Mặc dù đạt được các mục tiêu đề ra, nghiên cứu vẫn còn một số hạn chế cần được nhìn nhận khách quan:

- **Kích thước tập dữ liệu:** Với 197 mẫu sau tiền xử lý, tập dữ liệu tương đối nhỏ so với yêu cầu của nhiều thuật toán học máy phức tạp. Kích thước mẫu hạn chế có thể ảnh hưởng đến khả năng tổng quát hóa và là một trong những lý do khiến các mô hình phức tạp như XGBoost chưa phát huy hết ưu thế. Đây cũng là thách thức chung được ghi nhận trong lĩnh vực dự đoán hydrogen sinh học, nơi dữ liệu thường có kích thước hạn chế và phân bố lệch [19].
- **Dữ liệu từ một hệ thống reactor duy nhất:** Toàn bộ dữ liệu đến từ một hệ thống quy mô thử nghiệm với cơ chất sucrose. Do điều kiện tối ưu cho lên men hydrogen khác nhau đáng kể giữa các hệ thống và loại cơ chất [18], mô hình hiện tại chưa được kiểm chứng về khả năng áp dụng cho các reactor hoặc cơ chất khác.
- **Chưa khai thác yếu tố thời gian của dữ liệu:** Dữ liệu được ghi nhận tuần tự theo thời gian, nhưng các mô hình trong khóa luận xem mỗi mẫu là độc lập và chưa tận dụng thông tin về trình tự thời gian giữa các quan sát. Đây là một hướng có thể khai thác thêm khi có đủ dữ liệu.
- **Chưa tối ưu hóa siêu tham số:** Các mô hình chủ yếu sử dụng tham số mặc định hoặc cấu hình cơ bản (ví dụ $K = 5$ cho KNN). Việc tinh chỉnh siêu tham số một cách hệ thống (ví dụ bằng grid search kết hợp cross-validation) có thể cải thiện thêm hiệu suất nhưng chưa được thực hiện trong phạm vi khóa luận.
- **Hiện tượng đa cộng tuyến:** Một số đặc trưng có tương quan rất cao với nhau, như VFA với acetate và butyrate, điều này có thể làm cho việc diễn giải đóng góp riêng lẻ của từng đặc trưng trở nên phức tạp.

4.16 Hướng phát triển

Trên cơ sở các hạn chế nêu trên, một số hướng phát triển tiềm năng được đề xuất:

- **Mở rộng và đa dạng hóa dữ liệu:** Thu thập thêm dữ liệu từ nhiều reactor, nhiều loại cơ chất và điều kiện vận hành khác nhau để tăng kích thước mẫu và cải thiện khả năng tổng quát hóa của mô hình.
- **Mô hình chuỗi thời gian và học sâu:** Khi thu thập được tập dữ liệu lớn hơn từ nhiều lần vận hành, có thể thử nghiệm các mô hình khai thác cấu trúc thời gian (các mạng nơ-ron hồi quy hoặc Transformer) để nắm bắt động học của quá trình lên men theo thời gian.
- **Tối ưu hóa siêu tham số và kiểm định chéo:** Triển khai quy trình tinh chỉnh siêu tham số kết hợp k-fold cross-validation để đánh giá mô hình chặt chẽ hơn và khai thác tối đa hiệu suất của từng thuật toán.

- **Học chuyển giao:** Huấn luyện mô hình nền trên dữ liệu tổng hợp từ nhiều hệ thống, sau đó tinh chỉnh cho một reactor cụ thể nhằm giảm nhu cầu dữ liệu riêng cho từng hệ thống.
- **Triển khai giám sát thời gian thực:** Tích hợp mô hình dự đoán vào hệ thống giám sát trực tuyến, kết hợp cập nhật mô hình liên tục khi có dữ liệu mới, hướng tới hỗ trợ ra quyết định vận hành tự động cho bể phản ứng sinh học.

CHƯƠNG 5

KẾT LUẬN

Khóa luận đã xây dựng và đánh giá một quy trình tích hợp giữa GRA, học máy và SHAP để dự đoán tốc độ tạo hydro trong hệ thống lên men kỵ khí từ sucrose. Chương này tổng kết các đóng góp chính tương ứng với bốn mục tiêu và bốn câu hỏi nghiên cứu đã đặt ra, nêu ý nghĩa thực tiễn, và rút ra các bài học kinh nghiệm.

5.1 Đóng góp chính

Khóa luận đã hoàn thành bốn mục tiêu nghiên cứu đề ra:

Mục tiêu 1 – Xếp hạng đặc trưng bằng GRA: GRA xác định VFA (grade = 0.793), Butyrate (0.790), và Acetate (0.777) là ba yếu tố sinh hóa có ảnh hưởng lớn nhất đến HPR. Kết quả này nhất quán với cơ chế sinh học của lên men tối, trong đó các con đường trao đổi chất sản xuất acid béo bay hơi đồng thời giải phóng H_2 .

Mục tiêu 2 – Xây dựng và so sánh mô hình ML: Năm mô hình được huấn luyện và đánh giá. KNN đạt hiệu suất tốt nhất ($R^2 = 0.817$, RMSE = 2,49 L/h/L), tiếp theo là RF ($R^2 = 0.776$), XGBoost ($R^2 = 0.749$), SVR ($R^2 = 0.732$), và DT ($R^2 = 0.560$).

Mục tiêu 3 – Xác định tổ hợp đặc trưng tối ưu: Quy trình lựa chọn đặc trưng đa phương pháp (GRA + IG, sau đó thêm đặc trưng tuần tự từ top-3) cho thấy KNN đạt R^2 cao nhất (0.818) và gần như bão hòa từ 9 đặc trưng ($R^2 = 0.815$). Chỉ cần 3 đặc trưng hàng đầu là VFA, Butyrate và Acetate, RF đã đạt $R^2 = 0.775$.

Mục tiêu 4 – Giải thích mô hình bằng SHAP: Phân tích SHAP cho mô hình tối ưu KNN cho thấy Butyrate, VFA, Acetate và VSS có đóng góp lớn nhất – nhất quán mạnh với cả GRA và IG. Sự đồng thuận xuyên suốt ba phương pháp độc lập củng cố độ tin cậy của kết luận về các yếu tố then chốt, đồng thời mỗi phương pháp bổ sung một góc nhìn về quan hệ giữa đặc trưng và HPR.

5.2 Ý nghĩa thực tiễn

Kết quả nghiên cứu mang lại một số giá trị thực tiễn cho việc vận hành và giám sát hệ thống sản xuất hydrogen sinh học:

- **Giảm chi phí thí nghiệm:** Mô hình cho phép dự đoán HPR từ các thông số đo được, giảm nhu cầu thí nghiệm thăm dò tốn kém và mất thời gian.
- **Hỗ trợ vận hành:** Xếp hạng GRA chỉ ra rằng kỹ sư vận hành nên ưu tiên kiểm soát VFA, butyrate, và acetate để tối ưu HPR.

- **Đơn giản hóa giám sát:** Chỉ cần 3–4 thông số đầu vào đã đủ để dự đoán HPR với $R^2 > 0.75$, giảm chi phí phân tích mẫu và lắp đặt cảm biến.

Trả lời trực tiếp cho các câu hỏi nghiên cứu đặt ra ở Chương 1: nhóm acid béo bay hơi VFA, butyrate, acetate là các yếu tố ảnh hưởng mạnh nhất đến HPR (Câu hỏi 1); KNN cho hiệu suất dự đoán tốt nhất trên tập dữ liệu này, phản ánh đặc tính kích thước vừa phải và tính liên tục cao của dữ liệu (Câu hỏi 2); việc lựa chọn đặc trưng theo thứ hạng tổng hợp GRA + IG giúp duy trì hiệu suất với số đặc trưng ít hơn (Câu hỏi 3); và kết quả SHAP nhất quán mạnh với GRA và IG ở nhóm yếu tố then chốt, đồng thời bổ sung thông tin về cách mô hình khai thác từng đặc trưng (Câu hỏi 4).

5.3 Bài học kinh nghiệm

- Lựa chọn đặc trưng có vai trò quan trọng: chỉ với một nhóm nhỏ đặc trưng then chốt (top-3 đến top-4) các mô hình đã đạt phần lớn hiệu suất, và KNN gần như bão hòa từ 9 đặc trưng – cho thấy có thể giảm số đặc trưng đo lường mà không hy sinh nhiều độ chính xác.
- Mô hình đơn giản KNN có thể vượt trội mô hình phức tạp XGBoost khi tập dữ liệu nhỏ và đã chuẩn hóa tốt.
- Kết hợp phân tích GRA (trước huấn luyện) và SHAP (sau huấn luyện) cung cấp cái nhìn toàn diện hơn so với chỉ dùng một phương pháp.
- Dữ liệu từ hệ thống sinh học cần tiền xử lý cẩn thận – chuẩn hóa MinMaxScaler là bước thiết yếu cho các thuật toán dựa trên khoảng cách.

5.4 Tổng kết

Tóm lại, khóa luận đã chứng minh tính khả thi của việc kết hợp GRA, học máy và SHAP trong dự đoán và giải thích tốc độ tạo hydro của quá trình lên men kỵ khí từ sucrose. Quy trình đề xuất không chỉ cung cấp một mô hình dự đoán có độ chính xác chấp nhận được mà còn mang lại hiểu biết về vai trò của các yếu tố sinh hóa, qua đó kết nối giữa phân tích dữ liệu và cơ chế sinh học của quá trình. Mặc dù còn những hạn chế về kích thước và phạm vi dữ liệu, các kết quả đạt được tạo nền tảng cho những nghiên cứu tiếp theo nhằm phát triển các hệ thống giám sát và tối ưu vận hành bể phản ứng sinh học thông minh, góp phần thúc đẩy ứng dụng năng lượng hydrogen sinh học theo hướng bền vững.

PHỤ LỤC

Phụ lục A: Bảng công việc thực hiện

Khóa luận do một sinh viên thực hiện độc lập dưới sự hướng dẫn của TS. Nguyễn Bảo Ân. Bảng 5.1 tóm tắt các hạng mục công việc chính trong quá trình thực hiện đề tài.

Bảng 5.1: Các hạng mục công việc thực hiện

STT	Công việc	Người thực hiện
1	Thu thập, tiền xử lý và chuẩn hóa dữ liệu reactor	Trần Minh Điền
2	Phân tích GRA và xếp hạng đặc trưng	Trần Minh Điền
3	Huấn luyện, so sánh 5 mô hình ML và thêm đặc trưng tuần tự	Trần Minh Điền
4	Phân tích SHAP và giải thích mô hình	Trần Minh Điền
5	Viết và hoàn thiện báo cáo khóa luận	Trần Minh Điền

Phụ lục B: Tài liệu bổ sung

Mã nguồn, dữ liệu và các kết quả chi tiết của nghiên cứu được lưu trữ trong kho mã nguồn của dự án, bao gồm: quy trình huấn luyện mô hình (`train_pipeline.py`), các biểu đồ phân tích (thư mục `figures/`), và bảng kết quả chi tiết (định dạng CSV).

DANH MỤC TÀI LIỆU THAM KHẢO

Tiếng Anh

- [1] Ahmad F., Samreen I., Qureshi S. A., Aslam S., and Balogun H. (2024), “Machine learning-coupled response surface methodology for predicting the optimized bio-gas potential of biomass”, *Biomass and Bioenergy*, 180, pp. 107024.
- [2] Breiman L. (2001), “Random Forests”, *Machine Learning*, 45(1), pp. 5–32.
- [3] Chandrasekhar K., Kumar S., Lee B.-D., and Kim S.-H. (2020), “Waste based hydrogen production for circular bioeconomy: Current status and future directions”, *Bioresource Technology*, 302, pp. 122920.
- [4] Chen T. and Guestrin C. (2016), “XGBoost: A Scalable Tree Boosting System”, in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794.
- [5] Deng J.-L. (1989), “Introduction to Grey System Theory”, *The Journal of Grey System*, 1(1), pp. 1–24.
- [6] Esquivel-Elizondo S., Krajmalnik-Brown R., Maldonado J., and Rittmann B. E. (2017), “Insights into butyrate production in a controlled fermentation system via gene predictions”, *mSystems*, 2(4), pp. e00051–17.
- [7] Ghimire A., Frunzo L., Pirozzi F., Trably E., Escudie R., Lens P. N. L., and Esposito G. (2015), “A review on dark fermentative biohydrogen production from organic biomass: Process parameters and use of by-products”, *Applied Energy*, 144, pp. 73–95.
- [8] Hosseinzadeh A., Zhou J. L., Li X., Afsari M., and Shahba A. (2022), “Machine learning modeling and analysis of biohydrogen production from wastewater by dark fermentation process”, *Bioresource Technology*, 343, pp. 126111.
- [9] International Energy Agency (2020), *World Energy Outlook 2020*, IEA, Paris.
- [10] International Energy Agency (2024), *Global Hydrogen Review 2024*, IEA, Paris.
- [11] Kovalev A. A., Kovalev D. A., Litt Y. V., Katraeva I. V., Russkova Y. I., and Nozhevnikova A. N. (2021), “Effect of low digestate recirculation ratio on biofuel recovery and microbial community changes during pilot-scale dry thermophilic anaerobic digestion”, *International Journal of Hydrogen Energy*, 46(72), pp. 35568–35580.
- [12] Kraskov A., Stögbauer H., and Grassberger P. (2004), “Estimating Mutual Information”, *Physical Review E*, 69(6), pp. 066138.
- [13] Lay C.-H., Vo T.-P., Lin C.-Y., Abdul P. M., Liu C.-M., and Lin C.-Y. (2016), “Biohydrogen production in an anaerobic baffled stacking reactor: Nitrogen and kinetic study”, *Biochemical Engineering Journal*, 109, pp. 54–60.

- [14] Lin C.-Y., Wu S.-Y., Lin P.-J., Chang J.-S., Hung C.-H., Lee K.-S., Lay C.-H., Chu C.-Y., Cheng C.-H., Chang A. C., Wu J.-H., Chang F.-Y., Yang L.-H., Lee C.-W., and Lin Y.-C. (2011), “A pilot-scale high-rate biohydrogen production system with mixed microflora”, *International Journal of Hydrogen Energy*, 36(14), pp. 8758–8764.
- [15] Liu Y., Min J., Feng X., He Y., Liu J., and Wang Y. (2020), “A Review of Biohydrogen Productions from Lignocellulosic Precursor via Dark Fermentation: Perspective on Hydrolysate Composition and Electron-Equivalent Balance”, *Energies*, 13(10), pp. 2451.
- [16] Long F., Wang L., Cai W., Lesnik K., and Liu H. (2023), “Predicting the performance of medium-chain carboxylic acid (MCCA) production using machine learning algorithms and microbial electrolysis cells (MECs)”, *Bioresource Technology*, 370, pp. 128533.
- [17] Lundberg S. M. and Lee S.-I. (2017), “A Unified Approach to Interpreting Model Predictions”, in *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*, pp. 4765–4774.
- [18] Moussa R. N., Moussa N., and Dionisi D. (2022), “Hydrogen Production from Biomass and Organic Waste Using Dark Fermentation: An Analysis of Literature Data on the Effect of Operating Parameters on Process Performance”, *Processes*, 10(1), pp. 156.
- [19] Pandey A. K., Park J., Ko J., Joo H.-H., Raj T., Singh L. K., Singh N., and Kim S.-H. (2023), “Machine learning in fermentative biohydrogen production: Advantages, challenges, and applications”, *Bioresource Technology*, 370, pp. 128502.
- [20] Patel G. H., Havukainen J., Horttanainen M., Soukka R., and Tuomaala M. (2024), “Climate change performance of hydrogen production based on life cycle assessment”, *Green Chemistry*, 26, pp. 992–1006.
- [21] Pedregosa F., Varoquaux G., Gramfort A., Michel V., Thirion B., Grisel O., Blondel M., Prettenhofer P., Weiss R., Dubourg V., Vanderplas J., Passos A., Cournapeau D., Brucher M., Perrot M., and Duchesnay E. (2011), “Scikit-learn: Machine Learning in Python”, *Journal of Machine Learning Research*, 12, pp. 2825–2830.
- [22] Pei Z., Liu S., Jing Z., Zhang Y., Wang J., Liu J., Wang Y., Guo W., Li Y.-Y., Ren N.-Q., and Xiang W. (2022), “Understanding of the interrelationship between methane production and microorganisms in high-solid anaerobic co-digestion using microbial community assembly”, *Journal of Cleaner Production*, 373, pp. 133793.
- [23] Rani P., Yadav D. K., Yadav A., Bishnoi N. R., Kumar V., and Ram C. (2024), “Frontier in dark fermentative biohydrogen production from lignocellulosic biomass: Challenges and future prospects”, *Fuel*, 366, pp. 131187.

- [24] Rittmann S. and Herwig C. (2012), “A comprehensive and quantitative review of dark fermentative biohydrogen production”, *Microbial Cell Factories*, 11, pp. 115.
- [25] Saha P., Akash F. A., Shovon S. M., Monir M. U., Ahmed M. T., Khan M. F. H., Sarkar S. M., Islam M. K., Hasan M. M., Vo D.-V. N., Aziz A. A., Hossain M. J., and Akter R. (2023), “Grey, blue, and green hydrogen: A comprehensive review of production methods and prospects for zero-emission energy”, *International Journal of Green Energy*, 21(6), pp. 1383–1397.
- [26] Shannon C. E. (1948), “A Mathematical Theory of Communication”, *The Bell System Technical Journal*, 27(3), pp. 379–423.
- [27] Smola A. J. and Schölkopf B. (2004), “A tutorial on support vector regression”, *Statistics and Computing*, 14(3), pp. 199–222.
- [28] Song J., An D., Ren N., Zhang Y., and Chen Y. (2011), “Effects of pH and ORP on microbial ecology and kinetics for hydrogen production in continuously dark fermentation”, *Bioresource Technology*, 102(23), pp. 10875–10880.
- [29] Vo T.-P., Lay C.-H., and Lin C.-Y. (2019), “Effects of hydraulic retention time on biohythane production via single-stage anaerobic fermentation in a two-compartment bioreactor”, *Bioresource Technology*, 292, pp. 121869.
- [30] Wang R., Li C., Lv N., Pan X., Cai G., Ning J., and Zhu G. (2021), “Enhancing acetic and formic acids generation in acidogenesis of food waste by biological pretreatment”, *Water Research*, 193, pp. 116867.
- [31] Wang Z., Wu F., Hao N., Wang T., Cao N., and Wang X. (2024), “The combined machine learning model SMOTER-GA-RF for methane yield prediction during anaerobic digestion of straw lignocellulose based on random forest regression”, *Journal of Cleaner Production*, 466, pp. 142909.
- [32] Wei G.-W. (2011), “Grey relational analysis model for dynamic hybrid multiple attribute decision making”, *Knowledge-Based Systems*, 24(5), pp. 672–679.
- [33] Ju-Yong R., Yong-Woo K., and Yong-Seok C. (2019), “Comprehensive evaluation of marine waste heat recovery technologies based on Hierarchy-Grey relational analysis”, *Journal of Ocean Engineering and Science*, 4(4), pp. 308–316.